

CHAPITRE 1 REPRESENTATION DANS L'ESPACE D'ETAT ET FILTRAGE DE KALMAN

1.1 Introduction

Dans cette partie, nous introduisons le filtre de Kalman, approche récursive qui est très souvent exploitée en traitement du signal. Que ce soit dans le contexte du traitement de la parole, de l'analyse de signaux biomédicaux, de la navigation GPS, du traitement radar notamment pour la poursuite de cible, le filtre de Kalman a fait ses preuves. Il permet d'estimer de manière récursive les paramètres que l'on cherche à déterminer. Ces paramètres constituent l'ensemble ou une partie du vecteur dit « d'état » que l'on va estimer à partir des observations bruitées.

Ainsi, nous abordons le cas simple d'un système où la représentation du système dans l'espace d'état, à savoir les relations de mise à jour du vecteur d'état et d'observations, sont linéaires. Cependant, on peut aussi traiter du cas où ces relations sont non-linéaires. Dans ce cas, comme le problème d'estimation ne présente pas de solution analytique, il faut recourir à des méthodes sous-optimales. Parmi elles, le filtre de Kalman étendu (EKF), méthode « locale », consiste à linéariser le modèle d'état autour de la dernière estimation disponible du vecteur d'état. Si l'EKF est l'une des techniques les plus communément utilisées, il présente plusieurs inconvénients, dont des risques de divergence en cas de fortes non-linéarités. Des versions itératives ou le filtre de Kalman du second ordre peuvent être envisagées. Dans ce cas, il s'agit d'exploiter un développement de Taylor du second ordre autour de la dernière estimation du vecteur d'état disponible. D'autres méthodes, dites « globales », consistent à calculer une approximation de la distribution *a posteriori* de l'état. Les filtres SPKF¹ constituent une première famille d'approches dans laquelle on recense :

- ✓ le filtre de Kalman sans parfum (UKF) qui vise à approcher la distribution *a priori* du vecteur d'état par celle d'un vecteur aléatoire gaussien et repose sur la transformation sans parfum (« Unscented Transformation » en anglais, UT) ;
- ✓ le filtre de Kalman par différence centrale (CDKF) qui se fonde quant à lui sur la formule d'interpolation polynomiale de Stirling.

Enfin, d'autres variantes comme le filtre QKF et CKF pour « quadrature Kalman filter » et « cubature Kalman filter » ont été aussi proposées.

¹ Il est à noter que les filtrages par sigma-point ont été interprétés par Lefebvre et al. comme une approche visant à mener une linéarisation statistique pondérée de la transformation non-linéaire.

Une autre méthode globale correspond aux filtres particulaires, aussi appelés méthodes séquentielles de Monte-Carlo. Etant donné l'ensemble $Y_n = \{y(i)\}_{i=1,\dots,n}$ des n dernières observations disponibles et $X_n = \{x(i)\}_{i=1,\dots,n}$ la trajectoire suivie par le processus d'état de l'instant 1 à n , le filtrage particulaire consiste à estimer récursivement la distribution *a posteriori* du vecteur d'état $p(x(n)/Y_n)$ par marginalisation de la densité $p(X_n/Y_n)$. Cependant, cette dernière ne peut pas être simulée directement ; elle est donc approximée par échantillonnage d'importance à partir de la densité d'importance² notée $q(X_n|Y_n)$. Pour éviter de générer à chaque instant la totalité de la trajectoire $X_n = \{x(i)\}_{i=1,\dots,n}$, on opte pour une approche récursive qui tient compte des trajectoires passées. Les particules sont alors générées selon la densité $q(x(n)/X_{n-1}, Y_n)$. De plus, elles sont associées à des poids calculés de manière itérative qui reflètent leurs pertinences. Pour éviter la « dégénérescence » du nuage de particules, on effectue un ré-échantillonnage qui a pour but de sélectionner les particules les plus pertinentes pour l'estimation. Des filtres particulaires rao-blackwellisé peuvent dans certains cas être envisagés et visent à marginaliser une partie des variables d'état qui sont alors traités par filtrage de Kalman. Cependant, nous ne traiterons pas ces dernières approches dans ce chapitre.

Ce chapitre s'organise comme suit : nous introduisons tout d'abord la représentation dans l'espace d'état et donnons quelques exemples notamment dans le cas de mouvements effectués par un objet en mouvement ou dans le cas de signaux modélisés par des processus autorégressifs ou à moyenne ajustée. Puis, nous abordons l'estimation du vecteur d'état par filtrage de Kalman dans un cas linéaire puis dans un contexte non-linéaire.

1.2 Représentation du système dans l'espace d'état (REE)

1.2.1 Définitions

De manière classique, dans l'analyse des circuits et des signaux, on utilise des équations différentielles pour représenter le système. Cette représentation est une des plus naturelles car elle traduit de manière directe le comportement du système analysé. Elle peut aussi se ramener, sans qu'il y ait équivalence absolue, à une représentation par fonction de transfert.

Dans le cas d'un système stationnaire, la description du système peut être faite par une équation de convolution, qui est rigoureusement équivalente à une représentation par une fonction de transfert, puisque l'une est la transformée de Laplace de l'autre.

Ces représentations ont eu beaucoup de succès de par leur simplicité. Cependant, avec ce mode de représentation, il est difficile d'analyser les régimes transitoires ou non stationnaires. Par ailleurs, la représentation du système dans l'espace d'état permet de tirer profit de nombreux résultats disponibles sur l'algèbre linéaire et de dégager facilement des propriétés remarquables.

Soit $\underline{x}(t)$ un vecteur de dimension $p \times 1$ ayant les composantes $\{x_i(t)\}_{i=1,\dots,p}$:

$$\underline{x}(t) = [x_1(t) \quad \dots \quad x_p(t)]^T. \quad (1.1)$$

On appelle $\underline{x}(t)$ l'état du système, étant donné la valeur initiale $\underline{x}(t_0)$, l'ensemble minimal des composantes $x_1(t_0), \dots, x_p(t_0)$, permettant de déterminer $\underline{x}(t)$ pour une certaine entrée $\underline{u}(t)$ connue, pour tout $t > t_0$. En d'autres termes, l'état d'un système est un résumé

² C'est-à-dire représentée par une population d'échantillons, encore appelés particules échantillonnées indépendamment et identiquement selon la densité $q(X_n|Y_n)$.

d'informations suffisantes permettant de décrire l'évolution de ce système, étant donné les entrées.

Un système est décrit dans l'espace d'état si son fonctionnement ou son comportement est régi par l'équation différentielle suivante :

$$\dot{\underline{x}}(t) = A(t)\underline{x}(t) + B(t)\underline{w}(t), \quad (1.2)$$

où :

$$\dot{\underline{x}}(t) = \frac{d\underline{x}(t)}{dt}. \quad (1.3)$$

Le vecteur $\underline{x}(t)$ n'est pas forcément accessible par une mesure et, dans le cas général, il ne l'est qu'à travers d'une observation définie comme suit :

$$y(t) = H(t)\underline{x}(t). \quad (1.4)$$

Nous verrons que cette observation est souvent bruitée et qu'il y a lieu d'ajouter un terme de bruit à l'équation (1.4) pour une modélisation réaliste de la mesure.

1.2.2 Représentation dans l'espace d'état à partir de la représentation par équation différentielle

Considérons un système linéaire gouverné par l'équation différentielle suivante

$$y^{(p)}(t) + a_{p-1}y^{(p-1)}(t) + \dots + a_0y(t) = b_0w(t), \quad (1.5)$$

où :

$$y^{(p)}(t) = \frac{d^p y(t)}{dt^p}. \quad (1.6)$$

A partir de cette écriture, (1.5)-(1.6), nous avons la liberté de choisir plusieurs représentations possibles dans l'espace d'état. A titre d'exemple, construisons un vecteur d'état $\underline{x}(t)$ dont la première composante est $y(t)$ et les $p-1$ èmes suivantes sont les $p-1$ èmes dérivées de $y(t)$:

$$\begin{aligned} x_1(t) &= y(t) \\ x_2(t) &= \dot{y}(t) = \dot{x}_1(t) \\ &\vdots \\ x_p(t) &= y^{(p-1)}(t) = \dot{x}_{p-1}(t) \end{aligned} \quad (1.7)$$

Soit :

$$\underline{x}(t) = [x_1(t) \dots x_p(t)]^T \text{ et } \underline{w}(t) = [w(t)], \quad (1.8)$$

dès lors, nous pouvons écrire que :

$$\dot{\underline{x}}(t) = A(t)\underline{x}(t) + B(t)\underline{w}(t), \quad (1.2)$$

en posant :

$$A = \begin{bmatrix} 0 & 1 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 1 \\ -a_0 & -a_1 & \dots & -a_{p-1} \end{bmatrix} \text{ et } B = \begin{bmatrix} 0 \\ \vdots \\ 0 \\ b_0 \end{bmatrix}. \quad (1.9)$$

Compte tenu de (1.4) la matrice d'observation H prend, dans ce cas, la forme suivante :

$$H = [1 \quad 0 \quad \dots \quad 0]. \quad (1.10)$$

Remarque :

On dit que le système est stationnaire quand les matrices A , B et H ne varient pas au cours du temps.

1.2.3 Résolution des équations d'état

Reprenons les équations d'état données par les relations (1.2) et (1.4), dans le cas stationnaire :

$$\dot{\underline{x}}(t) = A\underline{x}(t) + B\underline{w}(t) \quad (1.2)$$

$$y(t) = H\underline{x}(t) \quad (1.4)$$

$\underline{x}(t)$ vérifie l'équation différentielle homogène suivante :

$$\dot{\underline{x}}(t) = A\underline{x}(t) \quad (1.11)$$

La solution de (1.11) est alors donnée par

$$\underline{x}(t) = \exp[A(t - t_0)] \underline{x}(0),$$

où :

$$\underline{x}(t_0) = \underline{x}(0).$$

La solution générale, dans le cas d'un système excité par une entrée $w(t)$ supposée continue par morceau, est alors donnée par l'équation suivante :

$$\underline{x}(t) = \exp[A(t - t_0)] \underline{x}(0) + \int_{t_0}^t \exp[A(t - \tau)] B \underline{w}(\tau) d\tau \quad (1.12)$$

Cette solution fait apparaître un premier terme associé à la solution générale de l'équation sans second membre et qui dépend des conditions initiales et un second terme de nature convolutive correspondant à une solution particulière dépendant de l'entrée du système. En outre, la quantité $\exp[A(t - t_0)]$ est appelée matrice de transition. Elle est souvent notée $\Phi(t - t_0)$.

1.2.4 Equations d'état dans le cas d'un système discret

Reprenons les équations décrivant les systèmes continus :

$$\dot{\underline{x}}(t) = A(t)\underline{x}(t) + B(t)\underline{w}(t) \quad (1.2)$$

$$y(t) = H(t)\underline{x}(t) \quad (1.4)$$

Pour les systèmes à temps discret, on peut :

✓ soit écrire de manière formelle les équations d'état sous la forme :

$$\underline{x}(k+1) = \Phi(k)\underline{x}(k) + G(k)\underline{u}(k) \quad (1.13)$$

$$y(k) = H(k)\underline{x}(k) + v(k) \quad (1.14)$$

où $u(k)$ et $v(k)$ sont les bruits de modèles et de mesure et G un vecteur de gain.

✓ soit discrétiser les équations continues.

Appliquons cette approche au travers de plusieurs exemples. Ainsi, dans le cas du traitement du signal radar pour le pistage d'une « cible » en mouvement ou dans un contexte de navigation GPS où il s'agit d'évaluer la position d'un récepteur GPS se déplaçant à partir

d'une constellation de satellites, il est nécessaire de définir un modèle d'évolution de l'objet qui doit être le plus fidèle possible à la réalité. Cet objet peut effectuer différents mouvements ou manœuvres au cours du temps.

Dans la suite, il s'agit de préciser ces mouvements et manœuvres. Nous nous intéressons en particulier aux mouvements dits rectilignes uniformes (MRU) et uniformément accélérés (MUA). Puis, nous donnons quelques éléments sur le modèle dit « de Singer » et sur le modèle de Singer modifié. Les modèles de mouvement sont exprimés dans un repère cartésien orthonormé $R = (x, y, z)$. x désigne la position de la cible, $\dot{x}$ sa vitesse et $\ddot{x}$ son accélération.

Cas du MRU

Dans le cas d'un objet dit « non manœuvrant », le modèle le plus simple que l'on peut envisager est celui d'un déplacement rectiligne et à vitesse « quasi-constante » en moyenne. L'accélération $w(t)$ est alors supposée blanche gaussienne centrée et de variance q avec $q = ngT$, où $g = 9.81 \text{ m.s}^{-2}$ et n est un nombre réel.

$$a(t) = \ddot{x}(t) = w(t) \quad (1.15)$$

On construit alors le vecteur d'état comme suit :

$$\underline{x}(t) = [x(t), \dot{x}(t)]^T \quad (1.16)$$

L'équation d'évolution du modèle à temps continu se définit alors de la manière suivante :

$$\begin{bmatrix} \dot{x}(t) \\ \ddot{x}(t) \end{bmatrix} = \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} x(t) \\ \dot{x}(t) \end{bmatrix} + \begin{bmatrix} 0 \\ 1 \end{bmatrix} w(t) \quad (1.17)$$

En posant $A = \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix}$ et $B = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$, il vient :

$$\dot{\underline{x}}(t) = A\underline{x}(t) + Bw(t) \quad (1.2)$$

Or, on a vu que

$$\underline{x}(t) = \exp[A(t - t_0)] \underline{x}(t_0) + \int_{t_0}^t \exp[A(t - \tau)] Bw(\tau) d\tau \quad (1.18)$$

En prenant $t = (k+1)T$ et $t_0 = kT$, il vient :

$$\underline{x}((k+1)T) = \exp[AT] \underline{x}(kT) + \int_{kT}^{(k+1)T} \exp[A((k+1)T - \tau)] Bw(\tau) d\tau \quad (1.19)$$

En effectuant le changement de variable $\tau = kT + \tau$ dans l'intégrale, on aboutit à :

$$\underline{x}((k+1)T) = \exp[AT] \underline{x}(kT) + \int_0^T \exp[A(T - \tau)] Bw(kT + \tau) d\tau \quad (1.20)$$

A ce stade du développement, en tirant profit de l'expression de la matrice A et du développement de Mc Laurin de $\exp[AT]$, à savoir :

$$\exp[AT] \approx I + AT = \begin{bmatrix} 1 & T \\ 0 & 1 \end{bmatrix} \quad (1.21)$$

il vient en tenant compte de la définition de B :

$$\underline{x}((k+1)T) = \begin{bmatrix} 1 & T \\ 0 & 1 \end{bmatrix} \underline{x}(kT) + \int_0^T \begin{bmatrix} 1 & T-\tau \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 0 \\ 1 \end{bmatrix} w(kT+\tau) d\tau \quad (1.22)$$

soit encore :

$$\underline{x}((k+1)T) = \begin{bmatrix} 1 & T \\ 0 & 1 \end{bmatrix} \underline{x}(kT) + \int_0^T \begin{bmatrix} T-\tau \\ 1 \end{bmatrix} w(kT+\tau) d\tau \quad (1.23)$$

En passant d'une analyse à temps continu à une analyse à temps discret, on aboutit à :

$$\underline{x}(k+1) = \Phi(k)\underline{x}(k) + \underline{u}(k) \quad (1.24)$$

Si la matrice de transition $\Phi(k)$ est à présent clairement précisée et vaut $\begin{bmatrix} 1 & T \\ 0 & 1 \end{bmatrix}$, il reste à définir la matrice de covariance du bruit de modèle que l'on note $Q = E[\underline{u}(k)\underline{u}(k)^T]$. Néanmoins, deux cas peuvent être envisagés, selon que $w(t)$ est constant sur une période d'échantillonnage ou pas. Intéressons-nous tout d'abord au premier cas ; comme

$$\underline{u}(k) = w(kT) \cdot \int_0^T \begin{bmatrix} T-\tau \\ 1 \end{bmatrix} d\tau = w(kT) \cdot \begin{bmatrix} \frac{T^2}{2} \\ T \end{bmatrix} \quad (1.25)$$

on a :

$$Q = E[\underline{u}(k)\underline{u}(k)^T] = q \cdot \begin{bmatrix} \frac{T^2}{2} \\ T \end{bmatrix} \cdot \begin{bmatrix} \frac{T^2}{2} & T \end{bmatrix} = q \cdot \begin{bmatrix} \frac{T^4}{4} & \frac{T^3}{2} \\ \frac{T^3}{2} & T^2 \end{bmatrix} \quad (1.26)$$

Dans le second cas,

$$\begin{aligned} Q = E[\underline{u}(k)\underline{u}(k)^T] &= q \cdot \int_0^T \begin{bmatrix} T-\tau \\ 1 \end{bmatrix} \cdot \begin{bmatrix} T-\tau & 1 \end{bmatrix} d\tau \\ &= q \cdot \int_0^T \begin{bmatrix} (T-\tau)^2 & T-\tau \\ T-\tau & 1 \end{bmatrix} d\tau = q \cdot \begin{bmatrix} \frac{T^3}{3} & \frac{T^2}{2} \\ \frac{T^2}{2} & T \end{bmatrix} \end{aligned} \quad (1.27)$$

Cas du MUA

Le second modèle mouvement souvent employé est celui dit « uniformément accéléré ». Dans ce cas, c'est l'accélération qui est supposée constante, ou « quasi-constante » en moyenne. La dérivée de l'accélération, appelée le jerk, est alors assimilée à un bruit blanc gaussien centré $w(t)$ de variance q :

$$\dot{a}(t) = \ddot{x}(t) = w(t) \quad (1.28)$$

Dans ce cas, le vecteur d'état comprend trois composantes : la position, la vitesse et l'accélération :

$$\underline{x} = [x, \dot{x}, \ddot{x}]^T \quad (1.29)$$

L'équation de mise à jour dans le domaine temporel continu de ce modèle de mouvement est alors :

$$\begin{bmatrix} \dot{x} \\ \ddot{x} \\ \ddot{x} \end{bmatrix} = \underbrace{\begin{bmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \\ 0 & 0 & 0 \end{bmatrix}}_A \begin{bmatrix} x \\ \dot{x} \\ \ddot{x} \end{bmatrix} + \underbrace{\begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}}_B \cdot w(t) \quad (1.30)$$

En procédant de la même façon que pour le mouvement rectiligne uniforme, on tire le développement de Maclaurin au second ordre de l'exponentielle $\exp[AT]$ qui satisfait :

$$\exp[AT] \approx I + AT + A^2 \frac{T^2}{2} = \begin{bmatrix} 1 & T & \frac{T^2}{2} \\ 0 & 1 & T \\ 0 & 0 & 1 \end{bmatrix} \quad (1.31)$$

D'où :

$$\begin{aligned} \underline{x}((k+1)T) &= \begin{bmatrix} 1 & T & \frac{T^2}{2} \\ 0 & 1 & T \\ 0 & 0 & 1 \end{bmatrix} \underline{x}(kT) \\ &+ \int_0^T \begin{bmatrix} 1 & T-\tau & \frac{(T-\tau)^2}{2} \\ 0 & 1 & T-\tau \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} w(kT+\tau) d\tau \end{aligned} \quad (1.32)$$

Soit encore

$$\underline{x}(k+1) = \begin{bmatrix} 1 & T & \frac{T^2}{2} \\ 0 & 1 & T \\ 0 & 0 & 1 \end{bmatrix} \underline{x}(k) + \int_0^T \begin{bmatrix} \frac{(T-\tau)^2}{2} \\ T-\tau \\ 1 \end{bmatrix} w(kT+\tau) d\tau \quad (1.33)$$

Comme précédemment, deux cas sont possibles. Si $w(t)$ n'est pas constant durant une période

d'échantillonnage, la matrice de corrélation de $\underline{u}(k) = \int_0^T \begin{bmatrix} \frac{(T-\tau)^2}{2} \\ T-\tau \\ 1 \end{bmatrix} w(kT+\tau) d\tau$ satisfait :

$$Q = E[\underline{u}(k)\underline{u}(k)^T] = q \int_0^T \begin{bmatrix} \frac{(T-\tau)^2}{2} \\ T-\tau \\ 1 \end{bmatrix} \begin{bmatrix} \frac{(T-\tau)^2}{2} & T-\tau & 1 \end{bmatrix} d\tau \quad (1.34)$$

soit

$$Q = q \cdot \begin{bmatrix} -\frac{(T-\tau)^5}{20} & -\frac{(T-\tau)^4}{8} & -\frac{(T-\tau)^3}{6} \\ \frac{(T-\tau)^4}{8} & \frac{(T-\tau)^3}{3} & T\tau - \frac{\tau^2}{2} \\ -\frac{(T-\tau)^3}{6} & T\tau - \frac{\tau^2}{2} & \tau \end{bmatrix}_0^T = q \cdot \begin{bmatrix} \frac{T^5}{20} & \frac{T^4}{8} & \frac{T^3}{6} \\ \frac{T^4}{8} & \frac{T^3}{3} & \frac{T^2}{2} \\ \frac{T^3}{6} & \frac{T^2}{2} & T \end{bmatrix} \quad (1.35)$$

Si, à présent, $w(t)$ ne varie pas sur une période d'échantillonnage, on a

$$\underline{u}(k) = w(kT) \cdot \int_0^T \begin{bmatrix} \frac{(T-\tau)^2}{2} \\ T-\tau \\ 1 \end{bmatrix} d\tau = w(kT) \cdot \begin{bmatrix} \frac{T^3}{6} \\ \frac{T^2}{2} \\ T \end{bmatrix} \quad (1.36)$$

La matrice de corrélation de $\underline{u}(k)$ vérifie alors :

$$Q = q \cdot \begin{bmatrix} \frac{T^3}{6} \\ \frac{T^2}{2} \\ T \end{bmatrix} \cdot \begin{bmatrix} \frac{T^3}{6} & \frac{T^2}{2} & T \end{bmatrix} = q \cdot \begin{bmatrix} \frac{T^6}{36} & \frac{T^5}{12} & \frac{T^4}{6} \\ \frac{T^5}{12} & \frac{T^4}{4} & \frac{T^3}{2} \\ \frac{T^4}{6} & \frac{T^3}{2} & T^2 \end{bmatrix} \quad (1.37)$$

Cas du modèle de Singer

Outre ces deux modèles de mouvement, on peut aussi être amené à s'intéresser à la représentation de manœuvres. Celles à coordonnées découplées telles que le modèle de Singer [SIN70] ou le modèle de Singer « modifié » sont particulièrement utilisées. Alors que dans le cas du MRU, l'accélération est représentée par un bruit blanc, dans le cas du modèle de Singer, l'accélération de variance σ_m^2 à l'instant t est supposée corrélée aux instants qui le précèdent ou le succèdent. Sa fonction d'autocorrélation est alors supposée de la forme suivante :

$$r_{\ddot{x}}(\tau) = \sigma_m^2 e^{-\frac{|\tau|}{\tau_m}} \quad (1.38)$$

Pour déterminer l'équation différentielle que vérifie l'accélération et en déduire la représentation dans l'espace d'état de l'objet suivant un modèle de Singer, on suppose que l'accélération résulte du filtrage d'un bruit blanc gaussien centré de variance q par un filtre de réponse impulsionnelle $h(t)$.

$$a(t) = \ddot{x}(t) = h(t) * w(t) \quad (1.39)$$

ce qui donne dans le domaine fréquentiel :

$$A(f) = H(f)W(f) \quad (1.40)$$

soit encore en s'intéressant à la relation liant les densités spectrales de puissance de $w(t)$ et de $\ddot{x}(t)$, il vient :

$$S_{\ddot{x}}(f) = TF(r_{\ddot{x}}(\tau)) = |H(f)|^2 S_{ww}(f) \quad (1.41)$$

où TF désigne la transformée de Fourier.

Or, on montre aisément que :

$$TF(r_{\ddot{x}}(\tau)) = \frac{\frac{2.\sigma_m^2}{\tau_m}}{(\frac{1}{\tau_m} + j2\pi f).(\frac{1}{\tau_m} - j2\pi f)} \quad (1.42)$$

Etant donné les deux équations ci-dessus, on déduit par identification que :

$$S_{ww}(f) = \frac{2.\sigma_m^2}{\tau_m} = q \quad (1.43)$$

et :

$$H(f) = \frac{1}{\frac{1}{\tau_m} + j2\pi f} \quad (1.44)$$

Etant donné l'expression (1.44) de $H(f)$ et la relation (1.40), on a donc

$$A(f).(\frac{1}{\tau_m} + j2\pi f) = W(f) \quad (1.45)$$

Cela revient à écrire dans le domaine temporel que l'accélération satisfait l'équation différentielle suivante :

$$\frac{1}{\tau_m} \ddot{x}(t) + \frac{d\ddot{x}(t)}{dt} = w(t) \quad (1.46)$$

En posant :

$$\alpha = \frac{1}{\tau_m} \quad (1.47)$$

On introduit alors le vecteur d'état à trois composantes suivant :

$$x = [x, \dot{x}, \ddot{x}]^T \quad (1.48)$$

Tirant profit de (1.46), il vient :

$$\begin{bmatrix} \dot{x} \\ \ddot{x} \\ \dddot{x} \end{bmatrix} = \begin{bmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \\ 0 & 0 & -\alpha \end{bmatrix} \begin{bmatrix} x \\ \dot{x} \\ \ddot{x} \end{bmatrix} + \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} . w(t) \quad (1.49)$$

A ce stade du développement, on opère de manière identique aux cas du MRU et du MUA.

Ainsi, on peut exprimer $\exp(AT)$ comme suit :

$$\begin{aligned} \exp[AT] &\approx I + \begin{bmatrix} 0 & T & 0 \\ 0 & 0 & T \\ 0 & 0 & -\alpha T \end{bmatrix} + \frac{1}{2} \begin{bmatrix} 0 & 0 & T^2 \\ 0 & 0 & -\alpha T^2 \\ 0 & 0 & \alpha^2 T^2 \end{bmatrix} + \dots \\ &\approx \begin{bmatrix} 1 & 0 & \frac{T^2}{2} \\ 0 & 1 & T - \frac{\alpha T^2}{2} + \dots \\ 0 & 0 & 1 - \alpha T + \frac{\alpha^2 T^2}{2} + \dots \end{bmatrix} \end{aligned} \quad (1.50)$$

On peut ainsi montrer que la matrice de passage traduisant la dynamique du vecteur d'état dans la représentation du système dans l'espace d'état à temps discret satisfait :

$$\Phi = \begin{bmatrix} 1 & T & \frac{1}{\alpha^2}(-1 + \alpha T + e^{-\alpha T}) \\ 0 & 1 & \frac{1}{\alpha}(1 - e^{-\alpha T}) \\ 0 & 0 & e^{-\alpha T} \end{bmatrix} \quad (1.51)$$

Quand α est petit, l'expression de cette matrice devient :

$$\Phi = \begin{bmatrix} 1 & T & \frac{T^2}{2} \\ 0 & 1 & T \\ 0 & 0 & 1 \end{bmatrix} \quad (1.52)$$

Dans ce cas, on a :

$$\begin{aligned} \underline{u}(k) &= \int_0^T \begin{bmatrix} 1 & T - \tau & \frac{1}{\alpha^2}(-1 + \alpha(T - \tau) + e^{-\alpha(T - \tau)}) \\ 0 & 1 & \frac{1}{\alpha}(1 - e^{-\alpha(T - \tau)}) \\ 0 & 0 & e^{-\alpha(T - \tau)} \end{bmatrix} \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} w(kT + \tau) d\tau \\ &= \int_0^T \begin{bmatrix} \frac{1}{\alpha^2}(-1 + \alpha(T - \tau) + e^{-\alpha(T - \tau)}) \\ \frac{1}{\alpha}(1 - e^{-\alpha(T - \tau)}) \\ e^{-\alpha(T - \tau)} \end{bmatrix} w(kT + \tau) d\tau \end{aligned} \quad (1.53)$$

et

$$Q = 2\alpha\sigma_m^2 \begin{bmatrix} q_{11} & q_{12} & q_{13} \\ q_{12} & q_{22} & q_{23} \\ q_{13} & q_{23} & q_{33} \end{bmatrix} \quad (1.54)$$

avec

$$\begin{cases} q_{11} = \frac{1}{2\alpha^5} \cdot (2\alpha T - 2\alpha^2 T^2 + 2\alpha^3 \frac{T^3}{3} - 4\alpha T e^{-\alpha T} - e^{-2\alpha T} + 1) \\ q_{12} = \frac{1}{2\alpha^4} \cdot (\alpha^2 T^2 + 1 + e^{-2\alpha T} + e^{-\alpha T} (-2 + 2\alpha T) - 2\alpha T) \\ q_{13} = \frac{1}{2\alpha^3} \cdot (1 - 2\alpha T e^{-\alpha T} - e^{-2\alpha T}) \\ q_{22} = \frac{1}{2\alpha^3} \cdot (2\alpha T - 3 + 4e^{-\alpha T} - e^{-2\alpha T}) \\ q_{23} = \frac{1}{2\alpha^2} \cdot (1 - e^{-\alpha T})^2 \\ q_{33} = -\frac{1}{2\alpha} \cdot (e^{-2\alpha T} - 1) \end{cases} \quad (1.55)$$

A noter que si $\alpha \gg 1$, les matrices de passage et de corrélation du bruit de modèle dans le cas du modèle de Singer tendent vers les expressions obtenues dans le cas d'un MRU avec $q = 2 \frac{\sigma_m^2}{\alpha}$. De même si α tend 0, les matrices de passage et de corrélation du bruit de modèle dans le cas du modèle de Singer tendent bien vers les expressions obtenues dans le cas d'un MUA avec $q = 2\alpha\sigma_m^2$.

Cas des modèles à coordonnées couplées (curviligne et rotationnel)

Outre le modèle de singer s'intégrant dans la famille des manœuvres à coordonnées découplées, les mouvements manœuvrants possèdent des coordonnées couplées peuvent être aussi étudiés et comprennent des mouvements de type curviligne ou rotationnel. Les développements présentés sont faits suivant les axes x et y . Ainsi, x et y désigne la position de la cible projetée sur les axes x et y , $\dot{x}$ et $\dot{y}$ désignent sa vitesse projetée sur les axes x et y , $\ddot{x}$ et $\ddot{y}$ désignent son accélération projetée sur les axes x et y .

Dans le cas d'un mouvement curviligne, et contrairement aux mouvements que nous avons introduits jusqu'à présent, on décompose l'accélération en deux composantes : l'accélération tangentielle $a_t(t)$ colinéaire au vecteur vitesse et l'accélération normale $a_n(t)$ qui permet de traduire les variations du vecteur vitesse au cours du temps. Il est à noter que le vecteur accélération est toujours orienté à l'intérieur de la trajectoire.

Pour définir un modèle curviligne, étant donné la figure 1.1., on peut d'ores et déjà préciser que :

$$\dot{v}(t) = a_t(t) \quad (1.56)$$

De plus, on peut exprimer les composantes du vecteur vitesse $v(t)$ comme suit :

$$\begin{cases} \dot{x}(t) = v(t) \cdot \cos(\phi(t)) \\ \dot{y}(t) = v(t) \cdot \sin(\phi(t)) \end{cases} \quad (1.57)$$

où $\phi(t)$ traduit la manière dont la vitesse de la cible évolue au cours du temps. Etant donné

$$(1.57), \text{ on observe que } \sqrt{\dot{x}^2 + \dot{y}^2} = v(t). \text{ De plus, } \begin{cases} \cos(\phi(t)) = \frac{\dot{x}(t)}{\sqrt{\dot{x}^2 + \dot{y}^2}} \\ \sin(\phi(t)) = \frac{\dot{y}(t)}{\sqrt{\dot{x}^2 + \dot{y}^2}} \end{cases}.$$

Dérivons dans un premier temps $\dot{x}(t)$ et $\dot{y}(t)$ et exprimons ces dérivées en fonction de $a_n(t)$ et $a_t(t)$. Ainsi, on a d'une part :

$$\begin{cases} \ddot{x}(t) = \dot{v}(t) \cdot \cos(\phi(t)) - \dot{\phi}(t) \cdot v(t) \cdot \sin(\phi(t)) \\ \ddot{y}(t) = \dot{v}(t) \cdot \sin(\phi(t)) + \dot{\phi}(t) \cdot v(t) \cdot \cos(\phi(t)) \end{cases} \quad (1.58)$$




Figure 1.1 : accélération normales et tangentielles dans un mouvement curviligne

D'autre part, $\ddot{x}$ et $\ddot{y}$ peuvent s'exprimer en fonction des composantes normales et tangentielles de l'accélération comme suit :

$$\begin{cases} \ddot{x}(t) = a_t(t) \cdot \cos(\phi(t)) - a_n(t) \cdot \sin(\phi(t)) \\ \ddot{y}(t) = a_t(t) \cdot \sin(\phi(t)) + a_n(t) \cdot \cos(\phi(t)) \end{cases} \quad (1.59)$$

Ainsi étant donné (1.58) et (1.59), il vient

$$\dot{\phi}(t) = \frac{a_n(t)}{v(t)} \quad (1.60)$$

En introduisant le vecteur d'état $\underline{x}(t) = [x(t), \dot{x}(t), y(t), \dot{y}(t)]^T$ et en notant $a = [a_t(t), a_n(t)]^T$, l'équation d'état du mouvement avec un bruit de modèle est alors :

$$\begin{pmatrix} \dot{x}(t) \\ \ddot{x}(t) \\ \dot{y}(t) \\ \ddot{y}(t) \end{pmatrix} = \underbrace{\begin{pmatrix} 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 \end{pmatrix}}_A \begin{pmatrix} x(t) \\ \dot{x}(t) \\ y(t) \\ \dot{y}(t) \end{pmatrix} + \underbrace{\begin{pmatrix} 0 & 0 \\ \frac{0}{\sqrt{\dot{x}^2 + \dot{y}^2}} & -\frac{\dot{y}}{\sqrt{\dot{x}^2 + \dot{y}^2}} \\ 0 & 0 \\ \frac{\dot{y}}{\sqrt{\dot{x}^2 + \dot{y}^2}} & \frac{\dot{x}}{\sqrt{\dot{x}^2 + \dot{y}^2}} \end{pmatrix}}_B \begin{pmatrix} a_t(t) \\ a_n(t) \end{pmatrix} + w(t) \quad (1.61)$$

La discrétisation de cette équation de mise à jour conduit à une équation de la forme :

$$\underline{x}(k+1) = \Phi \underline{x}(k) + G \underline{a}(k) + u(k) \quad (1.62)$$

On peut montrer que la matrice de transition Φ dans la représentation dans l'espace d'état est alors similaire à celle du MRU :

$$\Phi = \begin{pmatrix} 1 & T & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & T \\ 0 & 0 & 0 & 1 \end{pmatrix} \quad (1.63)$$

De la même façon, la matrice de covariance Q du bruit d'état est identique à celle du MRU.

La matrice d'entrée G du vecteur d'accélération doit être aussi déterminée.

Intéressons-nous enfin au cas d'un mouvement rotationnel. On introduit pour cela le centre instantané de rotation qui est le point autour duquel s'effectue la rotation entre deux instants successifs. Ses coordonnées sont notées (x_c, y_c) . On a donc, en introduisant la vitesse de rotation ω et la phase à l'origine φ :

$$\begin{cases} x(t) = x_c(t) + r \cos(\omega t + \varphi) \\ y(t) = y_c(t) + r \sin(\omega t + \varphi) \end{cases} \quad (1.64)$$

En dérivant une fois, il vient :

$$\begin{cases} \dot{x}(t) = -r\omega \sin(\omega t + \varphi) \\ \dot{y}(t) = r\omega \cos(\omega t + \varphi) \end{cases} \quad (1.65)$$

puis une seconde fois :

$$\begin{cases} \ddot{x}(t) = -r\omega^2 \cos(\omega t + \varphi) = -\omega \dot{y}(t) \\ \ddot{y}(t) = -r\omega^2 \sin(\omega t + \varphi) = \omega \dot{x}(t) \end{cases} \quad (1.66)$$

Deux choix peuvent alors être envisagés selon que l'on connaît la vitesse de rotation ω ou pas. Si elle n'est pas connue, on l'intègre dans le vecteur d'état qui comprend 5 composantes :

$$\underline{x} = [x, \dot{x}, y, \dot{y}, \omega]^T \quad (1.67)$$

Pour déterminer la représentation dans l'espace d'état et la manière dont sont reliées les composantes du vecteur d'état, tirons profit des expressions ci-dessus de la position, de la vitesse et de l'accélération à des instants discrets donnés. Ainsi :

$$\begin{aligned} x((k+1)T) &= x_c(t) + r \cos(\omega((k+1)T) + \varphi) \\ &= x_c(t) + r \cos(\omega kT + \varphi) \cos(\omega T) - r \sin(\omega kT + \varphi) \sin(\omega T) \\ &= x_c(t) + \dot{y}(kT) \frac{\cos(\omega T)}{\omega} + \dot{x}(kT) \frac{\sin(\omega T)}{\omega} \\ &= x(kT) - r \cos(\omega kT + \varphi) + \dot{y}(kT) \frac{\cos(\omega T)}{\omega} + \dot{x}(kT) \frac{\sin(\omega T)}{\omega} \\ &= x(kT) + \dot{y}(kT) \frac{\cos(\omega T) - 1}{\omega} + \dot{x}(kT) \frac{\sin(\omega T)}{\omega} \end{aligned} \quad (1.68)$$

De même, on a :

$$\begin{aligned}
y((k+1)T) &= y_c(t) + \sin(\omega((k+1)T) + \varphi) \\
&= y_c(t) + r \sin(\omega kT + \varphi) \cos(\omega T) + r \cos(\omega kT + \varphi) \sin(\omega T) \\
&= y_c(t) - \dot{x}(kT) \frac{\cos(\omega T)}{\omega} + \dot{y}(kT) \frac{\sin(\omega T)}{\omega} \\
&= y(kT) - r \sin(\omega kT + \varphi) - \dot{x}(kT) \frac{\cos(\omega T)}{\omega} + \dot{y}(kT) \frac{\sin(\omega T)}{\omega} \\
&= y(kT) + \dot{x}(kT) \frac{1 - \cos(\omega T)}{\omega} + \dot{y}(kT) \frac{\sin(\omega T)}{\omega}
\end{aligned} \tag{1.69}$$

Pr ailleurs, exprimons $\dot{x}((k+1)T)$:

$$\begin{aligned}
\dot{x}((k+1)T) &= -r\omega \sin(\omega((k+1)T) + \varphi) \\
&= -r\omega \sin(\omega kT + \varphi) \cos(\omega T) - r\omega \cos(\omega kT + \varphi) \sin(\omega T) \\
&= \dot{x}(kT) \cos(\omega T) - \dot{y}(kT) \sin(\omega T)
\end{aligned} \tag{1.70}$$

et

$$\begin{aligned}
\dot{y}((k+1)T) &= r\omega \cos(\omega((k+1)T) + \varphi) \\
&= \dot{x}(kT) \sin(\omega T) + \dot{y}(kT) \cos(\omega T)
\end{aligned} \tag{1.71}$$

On observe dans ce cas que la mise à jour du vecteur d'état est non-linéaire.

Si à présent la vitesse de rotation est connue, on considère un vecteur d'état à 6 composantes comme suit :

$$\underline{x} = [x, \dot{x}, \ddot{x}, y, \dot{y}, \ddot{y}]^T \tag{1.72}$$

Là encore, pour construire la représentation dans l'espace d'état, on cherche des relations entre les différentes composantes. On montre que :

$$x((k+1)T) = x(kT) + \dot{x}(kT) \frac{\sin(\omega T)}{\omega} + \ddot{x}(kT) \frac{1 - \cos(\omega T)}{\omega^2} \tag{1.73}$$

$$y((k+1)T) = y(kT) + \dot{y}(kT) \frac{\sin(\omega T)}{\omega} + \ddot{y}(kT) \frac{1 - \cos(\omega T)}{\omega^2} \tag{1.74}$$

$$\dot{x}((k+1)T) = \dot{x}(kT) \cos(\omega T) + \ddot{x}(kT) \frac{\sin(\omega T)}{\omega} \tag{1.75}$$

$$\dot{y}((k+1)T) = \dot{y}(kT) \cos(\omega T) + \ddot{y}(kT) \frac{\sin(\omega T)}{\omega} \tag{1.76}$$

$$\begin{aligned}
\ddot{x}((k+1)T) &= -\omega \dot{y}((k+1)T) = -\omega \dot{y}(kT) \cos(\omega T) - \omega \dot{x}(kT) \sin(\omega T) \\
&= -\omega \dot{x}(kT) \sin(\omega T) + \ddot{x}(kT) \cos(\omega T)
\end{aligned} \tag{1.77}$$

et

$$\ddot{y}((k+1)T) = -\omega \dot{x}(kT) \sin(\omega T) + \ddot{y}(kT) \cos(\omega T) \tag{1.78}$$

On est alors en mesure de déterminer la matrice de transition comme suit :

$$\begin{bmatrix} 1 & \frac{\sin(\omega T)}{\omega} & \frac{1 - \cos(\omega T)}{\omega^2} & 0 & 0 & 0 \\ 0 & \cos(\omega T) & \frac{\sin(\omega T)}{\omega} & 0 & 0 & 0 \\ 0 & -\omega \sin(\omega T) & \cos(\omega T) & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & \frac{\sin(\omega T)}{\omega} & \frac{1 - \cos(\omega T)}{\omega^2} \\ 0 & 0 & 0 & 0 & \cos(\omega T) & \frac{\sin(\omega T)}{\omega} \\ 0 & 0 & 0 & 0 & -\omega \sin(\omega T) & \cos(\omega T) \end{bmatrix}$$

1.2.5 Propriétés des systèmes décrits dans l'espace d'état

1.2.5.1 Introduction

Plusieurs résultats portant en particulier sur des notions d'observabilité et de commandabilité sont importants. L'observabilité joue un rôle crucial dans le contexte de la modélisation des signaux et la commandabilité caractérise les systèmes à commander.

1.2.5.2 Observabilité

L'observabilité caractérise la possibilité de retrouver l'état d'un système en observant la sortie. On peut l'exprimer de différentes manières. Nous retiendrons la définition suivante facile à établir :

un système est observable si la mesure de la sortie permet de retrouver l'état initial.

Dans ce qui suit, nous allons établir la condition d'observabilité de tels systèmes. Considérons l'équation d'observation $y(k)$ en l'absence de bruit, dans le cas stationnaire discret :

$$y(k) = H \underline{x}(k) \quad (1.79)$$

La dynamique du vecteur d'état étant régie par :

$$\underline{x}(k+1) = \Phi \underline{x}(k) \quad (1.80)$$

Exprimons, dès lors pour tout $k \in [0, p-1]$, l'observation $y(k)$ en fonction des matrices de transition Φ et d'observation H ainsi que du vecteur d'état à l'état initial $\underline{x}(0)$.

$$\begin{aligned} y(0) &= H \underline{x}(0) \\ y(1) &= H \underline{x}(1) = H \Phi \underline{x}(0) \\ y(2) &= H \underline{x}(2) = H \Phi^2 \underline{x}(0) \\ &\vdots \\ y(p-1) &= H \underline{x}(p-1) = H \Phi^{p-1} \underline{x}(0) \end{aligned} \quad (1.81)$$

soit, sous la forme matricielle :

$$\underline{Y} = \begin{bmatrix} y(0) \\ y(1) \\ \vdots \\ y(p-1) \end{bmatrix} = \begin{bmatrix} H \\ H\Phi \\ \vdots \\ H\Phi^{p-1} \end{bmatrix} \underline{x}(0) = \Psi \underline{x}(0) \quad (1.82)$$

avec la matrice d'observabilité :

$$\Psi = \begin{bmatrix} H^T & (H\Phi)^T & \dots & (H\Phi^{p-1})^T \end{bmatrix}^T. \quad (1.83)$$

Pour déterminer l'état initial $\underline{x}(0)$ à partir de l'observation $\underline{Y}$, il faut que la matrice d'observabilité Ψ soit non singulière. On peut donc énoncer la condition d'observabilité :

Pour qu'un système soit observable il faut que la matrice d'observabilité Ψ soit de rang plein.

1.2.5.3 Commandabilité

La commandabilité des systèmes traduit la possibilité que l'on a d'imposer une entrée qui amène le système depuis un état initial $\underline{x}(0)$ à un état final $\underline{x}(k)$ en un temps fini. C'est une propriété utile dans le domaine du contrôle notamment pour la conduite de procédés, le guidage d'aéronefs ou d'engins balistiques.

Elle peut paraître, à première vue, d'un intérêt limité en traitement du signal et des images où l'objectif est surtout la modélisation et l'identification, étant entendu, dans tous les cas, que l'entrée n'est pas accessible dans la quasi totalité des applications.

Nous donnons néanmoins l'une des conditions auxquelles doivent satisfaire les quantités Φ et G pour que soit commandable un système gouverné par le modèle discret décrit par les équations (1.2) et (1.4) :

Il faut que la matrice de commandabilité $\begin{bmatrix} G & \Phi G & \dots & \Phi^{p-1}G \end{bmatrix}$ soit de rang p .

1.2.5.4 Non unicité des représentations du système dans l'espace d'état

Reprenons la représentation :

$$\underline{x}(k+1) = \Phi(k)\underline{x}(k) + G(k)\underline{u}(k) \quad (1.13)$$

$$y(k) = H(k)\underline{x}(k) + v(k) \quad (1.14)$$

Un système peut avoir un nombre infini de représentations ; on peut passer de l'une à l'autre par une transformation non singulière T . Cela correspond à un changement de base dans l'espace d'état :

$$\begin{aligned} \underline{x}(k) &= T \underline{x}_T(k) \\ \underline{x}_T(k+1) &= T^{-1}\Phi T \underline{x}_T(k) + T^{-1}G u(k) \\ y(k) &= HT \underline{x}_T(k) + v(k) \end{aligned} \quad (1.84)$$

On rappelle que le triplet $[\Phi, G, H]$ est similaire, à une transformation non singulière T près au triplet suivant :

$$\left[\Phi_T = T^{-1}\Phi T, G_T = T^{-1}G, H_T = HT \right]. \quad (1.85)$$

On peut donc dégager différentes représentations, caractérisées par le triplet $\Phi(k)$, $G(k)$ et $H(k)$ et citer les représentations particulières suivantes :

- ✓ représentation dite de Jordan ;
- ✓ représentation « contrôlable » ou commandable ;
- ✓ représentation « observable ».

1.2.6 Exemple n°1 : représentation d'un processus AR dans l'espace d'état

La modélisation AR peut s'avérer adapté dans de nombreuses applications : parole, communications numériques et radar. Ainsi, en traitement de la parole à des fins de rehaussement, de compression ou d'analyse, le signal peut être modélisé par un processus autorégressif dont l'ordre est généralement compris entre 8 et 16. En communications numériques, le canal de propagation peut être approximé par un modèle AR. En traitement radar, bien que la modélisation AR ne repose sur aucun phénomène physique selon Abramovich, elle a fait ses preuves, avec une seule antenne en réception, dans plusieurs applications à savoir l'identification de types de fouillis de sol et la détection de petites cibles marines.

Considérons le processus AR d'ordre p :

$$y(k) = -\sum_{i=1}^p a_i y(k-i) + u(k) \quad (1.86)$$

On rappelle que le processus AR être vu comme la somme de deux termes : un terme de prédiction, de la forme $-\sum_{i=1}^p a_i y(k-i)$, fondé sur les p dernières valeurs du processus et un terme d'erreur noté $u(k)$. En supposant les paramètres AR connus, la valeur du processus à l'instant k nécessite donc la connaissance des p dernières valeurs du processus. Comme le vecteur d'état est composé des variables d'état qui permettent de décrire entièrement un système, on construit ici le vecteur d'état en concaténant les p dernières valeurs du processus :

$$\underline{x}(k) = \begin{bmatrix} y(k-p+1) & \cdots & y(k) \end{bmatrix}^T. \quad (1.87)$$

Remarque 1 :

On pourrait très bien prendre le vecteur d'état suivant :

$$\underline{x}(k) = \begin{bmatrix} y(k) & \cdots & y(k-p+1) \end{bmatrix}^T. \quad (1.88)$$

Remarque 2 :

On pourrait aussi considérer un vecteur d'état impliquant plus de p valeurs du processus, mais on ne peut pas en prendre moins que p étant donné (1.67).

La mise à jour du vecteur d'état correspond alors :

$$\underline{x}(k+1) = \Phi \underline{x}(k) + Gu(k) \quad (1.89)$$

où la matrice de transition Φ est dans sa forme dite compagnon :

$$\Phi = \begin{bmatrix} 0 & 1 & 0 & \cdots & 0 \\ 0 & 0 & 1 & \ddots & \vdots \\ \vdots & & \ddots & \ddots & 0 \\ \vdots & \cdots & \cdots & 0 & 1 \\ -a_p & -a_{p-1} & \cdots & \cdots & -a_1 \end{bmatrix} \quad (1.90)$$

et G le vecteur d'entrée est défini par :

$$G = \begin{bmatrix} 0 & \cdots & 0 & 1 \\ \underbrace{\hspace{1cm}}_{p-1} \end{bmatrix}^T. \quad (1.91)$$

1.2.7 Exemple n°2 : représentation d'un processus V-AR dans l'espace d'état

Le modèle AR présenté dans la section précédente est utilisé dans de nombreux domaines tels que le traitement de données sismiques, le traitement de la parole, les systèmes de communication mobile, l'économétrie, le sonar et le radar. Quand plusieurs capteurs sont exploités, on peut opter pour l'extension du modèle AR au cas vectoriel (VAR). Ainsi, le modèle VAR suppose que le signal $\underline{y}(k)$, vecteur de taille $N \times 1$ composé des échantillons reçus par les N capteurs, s'exprime comme la somme d'une combinaison linéaire des p vecteurs $\{\underline{y}(k-i)\}_{i=1,\dots,p}$ et d'un vecteur erreur $\underline{u}(k)$:

$$A^p(0)\underline{y}(k) = -\sum_{i=1}^p A^p(i)\underline{y}(k-i) + \underline{u}(k) \quad (1.92)$$

où p désigne l'ordre du modèle, $\{A^p(i)\}_{i \in \{0,\dots,p\}}$ sont les matrices AR de taille $N \times N$ et $\underline{u}(k)$ représente le processus générateur vectoriel de taille $N \times 1$.

Si l'on introduit le polynôme $A_p(z)$:

$$A_p(z) = I_N + A^p(1)z^{-1} + A^p(2)z^{-2} + \dots + A^p(p)z^{-p}, \quad (1.93)$$

A noter que la stabilité du système est garantie si les racines $\{p_i\}_{i=1,\dots,pN}$ du déterminant de $A_p(z)$ sont situées à l'intérieur du cercle unité du plan complexe z .

Afin d'établir la représentation dans l'espace d'état du système, le vecteur colonne $\theta(m)$ de taille $N^2 p \times 1$, qui contient les coefficients $\left\{ \begin{matrix} i=1,\dots,p \\ a_{nl}^i \end{matrix} \right\}_{\substack{n=1,\dots,N \\ l=1,\dots,N}}$ des matrices AR $\{A^p(i)\}_{i=1,\dots,p}$, comme suit :

$$\underline{x}(k) = \begin{bmatrix} a_{11}^1(k) & \dots & a_{1N}^1(k) & \dots & a_{11}^p(k) & \dots & a_{1N}^p(k) & \dots & a_{N1}^1(k) & \dots & a_{NN}^1(k) & \dots & a_{N1}^p(k) & \dots & a_{NN}^p(k) \end{bmatrix} \quad (1.94)$$

1.2.8 Exemple n°3 : représentation des modèles MA dans l'espace d'état

Considérons le modèle MA d'ordre p :

$$y(k) = b_0 u(k) + \dots + b_p u(k-p) \quad (1.95)$$

Supposons la valeur des paramètres MA connue. Pour faciliter l'écriture de la représentation dans l'espace d'état du système (1.95), on introduit les processus suivants :

$$x_j(k) = \sum_{i=1}^{p+1-j} b_{i+j-1} u(k-i), \quad j \in \{1, \dots, p\}. \quad (1.96)$$

En effet, on constate d'une part que :

$$\begin{aligned} y(k) &= \sum_{l=0}^p b_l u(k-l) = \sum_{l=1}^p b_l u(k-l) + b_0 u(k) \\ &= x_1(k) + b_0 u(k) \end{aligned} \quad (1.97)$$

D'autre part, pour tout $j \in \{1, \dots, p-1\}$, on a :

$$\begin{aligned} x_j(k) &= \sum_{i=1}^{p+1-j} b_{i+j-1} u(k-i) = \sum_{l=0}^{p-2-j} b_{j+l} u(k-1-l) \\ &= \sum_{l=1}^{p-2-j} b_{j+l} u(k-1-l) + b_j u(k-1) \\ &= x_{j+1}(k-1) + b_j u(k-1) \end{aligned} \quad (1.98)$$

On peut alors construire le vecteur d'état comme suit :

$$\underline{x}(k) = [x_1(k) \quad \dots \quad x_p(k)]^T. \quad (1.99)$$

La mise à jour du vecteur d'état correspond alors à :

$$\underline{x}(k) = \begin{bmatrix} x_1(k) \\ x_2(k) \\ \vdots \\ \vdots \\ x_p(k) \end{bmatrix} = \begin{bmatrix} 0 & 1 & 0 & \dots & 0 \\ 0 & \ddots & \ddots & \ddots & \vdots \\ \vdots & \ddots & \ddots & \ddots & 0 \\ \vdots & & \ddots & \ddots & 1 \\ 0 & \dots & \dots & 0 & 0 \end{bmatrix} \begin{bmatrix} x_1(k-1) \\ x_2(k-1) \\ \vdots \\ \vdots \\ x_p(k-1) \end{bmatrix} + \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ \vdots \\ b_p \end{bmatrix} u(k-1). \quad (1.100)$$

et

$$y(k) = [1 \quad 0 \quad \dots \quad \dots \quad 0] \underline{x}(k) + b_0 u(k). \quad (1.101)$$

1.2.9 Exemple n°4 : représentation des modèles ARMA dans l'espace d'état

Considérons le modèle ARMA d'ordre (p, q) . Pour simplifier l'écriture, nous prenons $p = q$:

$$y(k) + a_1 y(k-1) + \dots + a_p y(k-p) = b_0 u(k) + \dots + b_p u(k-p) \quad (1.102)$$

Nous nous proposons dans ce paragraphe de donner une représentation de ce modèle dans l'espace d'état. Nous nous attachons à une forme dite observable, appropriée à l'estimation des paramètres du modèle. Notons que cet objectif se confond avec celui des automaticiens dans le cas d'identification des processus. On supposera les paramètres AR et MA connus.

On peut écrire $y(k)$ en introduisant des sorties auxiliaires notées $x_1(k), x_2(k), \dots, x_p(k)$ et définies successivement comme suit :

$$y(k) = b_0 u(k) + x_1(k) \quad (1.103)$$

où la première sortie auxiliaire vérifie :

$$\begin{aligned} x_1(k) &= [b_1 u(k-1) - a_1 y(k-1)] + \dots + [b_p u(k-p) - a_p y(k-p)] \\ &= [b_1 u(k-1) - a_1 y(k-1)] + x_2(k-1) \end{aligned} \quad (1.104)$$

En tenant compte de la relation (1.103) à l'instant $k-1$, l'expression (1.104) de $x_1(k)$ devient :

$$\begin{aligned} x_1(k) &= \left[b_1 u(k-1) - a_1 \left[b_0 u(k-1) + x_1(k-1) \right] \right] + x_2(k-1) \\ &= (b_1 - a_1 b_0) u(k-1) - a_1 x_1(k-1) + x_2(k-1) \end{aligned} \quad (1.105)$$

De la même manière, on définit la deuxième sortie auxiliaire :

$$\begin{aligned} x_2(k-1) &= \left[b_2 u(k-2) - a_2 y(k-2) \right] + \dots + \left[b_p u(k-p) - a_p y(k-p) \right] \\ &= \left[b_2 u(k-2) - a_2 y(k-2) \right] + x_3(k-2) \end{aligned} \quad (1.106)$$

L'expression de $x_2(k-1)$ devient :

$$\begin{aligned} x_2(k-1) &= \left[b_2 u(k-2) - a_2 \left[b_0 u(k-2) + x_1(k-2) \right] \right] + x_3(k-2) \\ &= (b_2 - a_2 b_0) u(k-2) - a_2 x_1(k-2) + x_3(k-2) \end{aligned} \quad (1.107)$$

soit à l'instant k :

$$x_2(k) = (b_2 - a_2 b_0) u(k-1) - a_2 x_1(k-1) + x_3(k-1) \quad (1.108)$$

Les autres sorties auxiliaires $x_i(k)$ se déduisent de façon identique. En particulier, on a :

$$\begin{aligned} x_p(k-p+1) &= \left[b_p u(k-p) - a_p y(k-p) \right] \\ &= (b_p - a_p b_0) u(k-p) - a_p x_1(k-p) \end{aligned} \quad (1.109)$$

soit à l'instant k :

$$x_p(k) = (b_p - a_p b_0) u(k-1) - a_p x_1(k-1) \quad (1.110)$$

En mettant ces équations sous forme matricielle, les différentes sorties x_i apparaissent telles les composantes d'un vecteur d'état :

$$\underline{x}(k+1) = \begin{bmatrix} x_1(k+1) & \dots & x_p(k+1) \end{bmatrix}^T,$$

qui sont exprimées en fonction de l'entrée $u(k)$.

On peut alors écrire l'ensemble des équations précédentes sous la forme habituelle des équations d'état :

$$\begin{bmatrix} x_1(k) \\ x_2(k) \\ \vdots \\ x_{p-1}(k) \\ x_p(k) \end{bmatrix} = \begin{bmatrix} -a_1 & 1 & 0 & \dots & 0 \\ -a_2 & 0 & \ddots & \ddots & \vdots \\ \vdots & 0 & \ddots & \ddots & 0 \\ -a_{p-1} & \vdots & \ddots & \ddots & 1 \\ -a_p & 0 & \dots & 0 & 0 \end{bmatrix} \begin{bmatrix} x_1(k-1) \\ x_2(k-1) \\ \vdots \\ x_{p-1}(k-1) \\ x_p(k-1) \end{bmatrix} + \begin{bmatrix} b_1 - a_1 b_0 \\ b_2 - a_2 b_0 \\ \vdots \\ b_{p-1} - a_{p-1} b_0 \\ b_p - a_p b_0 \end{bmatrix} u(k-1) \quad (1.111)$$

et

$$y(k) = \begin{bmatrix} 1 & 0 & \cdots & 0 \end{bmatrix} \begin{bmatrix} x_1(k) \\ x_2(k) \\ \vdots \\ x_p(k) \end{bmatrix} + b_0 u(k) \quad (1.112)$$

Remarque :

Les relations (1.100)-(1.101) correspondent bien à un cas particulier des relations (1.111)-(1.112) quand les paramètres $\{a_i\}_{i=1,\dots,p}$ sont nuls.

Remarque 2 :

Ces équations d'état peuvent être aussi interprétées comme représentant un filtre numérique d'entrée $u(k)$ et de sortie $y(k)$. Cette forme d'équation d'état est alors appelée forme observable, la matrice d'observabilité pour $a_p \neq 0$ étant toujours non singulière.

Etant donné le modèle ARMA, la représentation canonique est définie par les équations suivantes :

$$\underline{x}(k) = J \underline{x}(k-1) + \underline{\theta} y(k-1) + B u(k-1) \quad (1.113)$$

$$y(k) = H \underline{x}(k) + b_0 u(k) \quad (1.114)$$

$$\text{où } J = \begin{bmatrix} 0 & 0 & \cdots & 0 & 0 \\ 1 & 0 & \cdots & 0 & 0 \\ 0 & 1 & \cdots & 0 & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & \cdots & 1 & 0 \end{bmatrix}, \underline{\theta} = - \begin{bmatrix} a_p \\ \vdots \\ a_1 \end{bmatrix}, B = \begin{bmatrix} b_p \\ \vdots \\ b_1 \end{bmatrix} \text{ et } H = [0 \quad \cdots \quad 0 \quad 1]. \quad (1.115)$$

La matrice J possède les propriétés suivantes :

$$1. \quad J^i = 0 \quad \forall i \geq \rho \quad (1.116)$$

$$2. \quad HJ^i = \begin{bmatrix} \underbrace{0 \cdots 0}_{p-i-1} & 1 & \underbrace{0 \cdots 0}_i \end{bmatrix} \quad (1.117)$$

Cette présentation a l'avantage de faire apparaître de manière explicite les paramètres à identifier.

1.2.10 Exemple n°5 : représentation d'un processus bruité dans l'espace d'état

Dans de nombreuses situations, on peut être amené à modéliser un signal perturbé par un bruit de mesure additif. Il faut alors représenter le système correspondant dans l'espace d'état notamment pour estimer le signal à partir des observations bruitées. Pour cette raison, nous nous proposons de donner ici quelques illustrations complémentaires de représentation.

1.2.10.1 Processus AR perturbé par un bruit blanc

Considérons le premier cas d'un processus AR perturbé par un bruit additif blanc $b(k)$ de moyenne nulle et variance R . On suppose les paramètres AR connus ou préalablement estimés. L'observation dont on dispose est alors donnée par :

$$z(k) = y(k) + b(k) \quad (1.118)$$

Le vecteur d'état $\underline{x}(k)$ est celui que nous avons défini à l'équation (1.87). L'équation de remise à jour du vecteur d'état est alors celle vue en (1.89) alors que l'équation d'observation satisfait :

$$y(k) = H\underline{x}(k) + b(k) \quad (1.119)$$

où

$$G = H^T = \begin{bmatrix} 0 & \cdots & 0 & 1 \\ \underbrace{\hspace{1cm}}_{p-1} \end{bmatrix}^T \quad (1.120)$$

1.2.10.2 Processus AR perturbé par un bruit coloré, modélisé par un processus AR

On peut être amené à traiter un signal perturbé par un bruit coloré $b(k)$. On fait l'hypothèse que les paramètres AR du signal et du bruit sont supposés connus ou préalablement estimés.

Quand le bruit est coloré, il peut être modélisé comme le filtrage d'un bruit blanc. Supposons tout d'abord que ce filtrage soit à réponse impulsionnelle infini. Dans ce cas, le bruit coloré additif peut être vu tel un processus AR d'ordre q défini comme suit :

$$b(k) = -\sum_{j=1}^q c_j b(k-j) + w(k) \quad (1.121)$$

où la séquence $w(k)$ est blanche, gaussienne, de moyenne nulle, de variance W et indépendante du processus générateur $u(k)$ du signal $y(k)$.

Contrairement au cas précédent décrit dans la section 1.2.10.1, la corrélation qui existe au niveau du bruit doit être prise en compte dans la représentation du système dans l'espace d'état. Le vecteur d'état $\underline{x}(k)$ est donc formé des p dernières valeurs du signal et des q dernières valeurs du bruit additif :

$$\underline{x}(k) = \begin{bmatrix} \underline{s}^T(k) & \underline{v}^T(k) \end{bmatrix}^T \quad (1.122)$$

où
$$\underline{s}(k) = \begin{bmatrix} s(k-p+1) & \cdots & s(k) \end{bmatrix}^T \quad (1.123)$$

et
$$\underline{b}(k) = \begin{bmatrix} b(k-q+1) & \cdots & b(k) \end{bmatrix}^T. \quad (1.124)$$

L'observation disponible est alors définie comme suit

$$z(k) = y(k) + \underline{b}(k) = H\underline{x}(k) \quad (1.125)$$

où

$$H = \begin{bmatrix} 0 & \cdots & 0 & 1 & 0 & \cdots & 0 & 1 \\ \underbrace{\hspace{1cm}}_{p-1} & & \underbrace{\hspace{1cm}}_{q-1} \end{bmatrix} \quad (1.126)$$

Dans ce cas, la dynamique du vecteur d'état $\underline{x}(k)$ se traduit par l'équation :

$$\underline{x}(k) = \Phi \underline{x}(k-1) + G \underline{\gamma}(k). \quad (1.127)$$

où la matrice de transition Φ est partitionnée de la manière suivante :

$$\Phi = \begin{bmatrix} \Phi_s & 0 \\ 0 & \Phi_v \end{bmatrix} \quad (1.128)$$

avec

$$\Phi_s = \begin{bmatrix} 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 1 \\ -a_p & -a_{p-1} & \cdots & -a_1 \end{bmatrix} \quad (1.129)$$

et

$$\Phi_v = \begin{bmatrix} 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 1 \\ -c_q & -c_{q-1} & \cdots & -c_1 \end{bmatrix}. \quad (1.130)$$

Les matrices G et H sont définies par :

$$G = \begin{bmatrix} 0 & \cdots & 0 & 1 & 0 & \cdots & 0 \\ 0 & \cdots & 0 & 0 & \cdots & 0 & 1 \end{bmatrix}^T \quad (1.131)$$

alors le vecteur des « bruits » est construit de la manière suivante :

$$\underline{\gamma}(k) = [u(k) \quad w(k)]^T \quad (1.132)$$

La représentation dans l'espace d'état du système défini par le signal contaminé par le bruit coloré AR est dite représentation à « mesures parfaites » du fait que le bruit n'apparaît plus dans la relation (1.125). En effet, l'observation est une combinaison linéaire des variables d'état. Aucun autre terme n'intervient dans l'équation d'observation de la représentation dans l'espace d'état.

1.2.10.3 Processus AR perturbé par un bruit coloré modélisé par un processus MA

Supposons maintenant que le bruit $b(k)$ soit modélisé par un processus à MA d'ordre q comme suit :

$$b(k) = \sum_{i=0}^q c_i w(k-i) \quad (1.133)$$

où $\{c_i\}_{i=0,\dots,q}$ sont les paramètres MA et $w(k)$ est un bruit blanc gaussien à moyenne nulle et de variance σ_w^2 .

Introduisons les processus suivants :

$$\xi_j(k) = \sum_{i=1}^{q+1-j} c_{i+j-1} w(k-i), \quad j \in \{1, \dots, q\}. \quad (1.134)$$

A l'aide des équations (1.118), (1.133) et (1.96), on peut écrire :

$$\begin{aligned}
z(k) &= y(k) + \sum_{i=0}^q c_i w(k-i) \\
&= y(k) + \sum_{i=1}^q c_i w(k-i) + c_0 w(k) \\
&= y(k) + \xi_1(k) + c_0 w(k).
\end{aligned} \tag{1.135}$$

Définissons alors le processus $v(k) = c_0 w(k)$. Il s'agit d'un bruit blanc gaussien à moyenne nulle et de variance $R = \sigma_v^2 = c_0^2 \sigma_w^2$. Nous pouvons alors écrire (1.135) de la manière suivante :

$$z(k) = y(k) + \xi_1(k) + v(k). \tag{1.136}$$

On définit ensuite le vecteur d'état comme suit :

$$\underline{x}(k) = [y(k) \quad \cdots \quad y(k-p+1) \quad \xi_1(k) \quad \cdots \quad \xi_q(k)]^T, \tag{1.137}$$

La représentation dans l'espace d'état correspondant au système (1.118), (1.133) et (1.96) s'écrit alors :

$$\begin{cases} \underline{x}(k) = \Phi \underline{x}(k-1) + G \underline{u}(k) \\ z(k) = H \underline{x}(k) + v(k) \end{cases}. \tag{1.138}$$

Les matrices de cette représentation dans l'espace d'état (1.138) sont définies par :

$$\Phi = \begin{bmatrix} -a_1 & \cdots & \cdots & -a_p & & & & \\ 1 & 0 & 0 & 0 & & & & \\ 0 & \ddots & 0 & \vdots & & & & \\ 0 & 0 & 1 & 0 & & & & \\ & & & & O(p,q) & & & \\ & & & & 0 & 1 & 0 & 0 \\ & & & & 0 & \ddots & \ddots & 0 \\ & & O(q,p) & & \vdots & & \ddots & 1 \\ & & & & 0 & \cdots & \cdots & 0 \end{bmatrix} \tag{1.139}$$

$$G = \begin{bmatrix} H_p^T & O(p,1) \\ O(q,1) & \Gamma_n \end{bmatrix} \tag{1.140}$$

$$H = [H_p \quad H_q] \tag{1.141}$$

avec $\Gamma_n = [c_1 \quad \cdots \quad c_q]^T$. Pour tous les entiers positifs m et n , $H_m = \begin{bmatrix} 1 & \underbrace{0 \quad \cdots \quad 0}_{m-1} \end{bmatrix}$ est un vecteur ligne contenant $m-1$ zéros et $O(m,n)$ est la matrice nulle de taille $m \times n$.

D'autre part, le processus générateur $\underline{u}(k)$ est maintenant défini par :

$$\underline{u}(k) = \begin{bmatrix} u(k) \\ w(k-1) \end{bmatrix} \tag{1.142}$$

qui est un vecteur gaussien à moyenne nulle et de matrice de covariance $Q = \begin{bmatrix} \sigma_u^2 & 0 \\ 0 & \sigma_w^2 \end{bmatrix}$.

Remarquons que dans ce cas, la représentation d'état n'est plus à « mesures parfaites ».

1.2.10.4 Estimer un processus AR et ses paramètres lorsque l'on ne dispose que des observations perturbées par un bruit blanc

Dans le cas où l'on souhaite à la fois estimer le processus AR et ses paramètres à partir des observations bruitées, le vecteur d'état rassemblent à la fois les p dernières valeurs et les p paramètres AR. On a donc :

$$\underline{x}(k) = [a_p \quad \cdots \quad a_1 \quad y(k-p+1) \quad \cdots \quad y(k)]^T. \quad (1.143)$$

Dans ce cas, la dynamique du vecteur d'état $\underline{x}(k)$ se traduit par l'équation :

$$\underline{x}(k) = \Phi \underline{x}(k-1) + Gu(k). \quad (1.144)$$

où la matrice de transition Φ est partitionnée de la manière suivante :

$$\Phi = \begin{bmatrix} I_p & 0_p \\ 0_p & \Phi_s \end{bmatrix} \quad (1.145)$$

avec

$$\Phi_s = \begin{bmatrix} 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 1 \\ -a_p & -a_{p-1} & \cdots & -a_1 \end{bmatrix}. \quad (1.146)$$

$$G = \begin{bmatrix} \underbrace{0 \quad \cdots \quad 0}_p & \underbrace{0 \quad \cdots \quad 0}_{p-1} & 1 \end{bmatrix}^T \quad (1.147)$$


Etant donné (1.145), on peut réécrire (1.144) comme suit :

$$\underline{x}(k) = \begin{bmatrix} I_p & 0_p \\ 0_p & \Phi_s \end{bmatrix} \underline{x}(k-1) + \begin{bmatrix} 0_{p \times 1} \\ 0 \end{bmatrix} \underline{x}^T(k-1) \begin{bmatrix} 0_p & I_p \\ 0_p & 0_p \end{bmatrix} \underline{x}(k-1) + Gu(k). \quad (1.148)$$

Dans ce cas, on observe que la remise à jour du vecteur d'état ne se fait pas selon une relation linéaire.

1.2.11 Exemple n°6 : contexte GPS

-



Le principe de localisation GPS repose sur l'émission de signaux codés pseudo-aléatoires véhiculés par une onde porteuse. Le récepteur GPS dont la position est définie par les coordonnées x , y et z dans le système de coordonnées Earth Centered Earth Fixed (ECEF)³ communique avec des satellites en vue dont les positions x_i , y_i et z_i sont connues avec une très grande précision. On est donc en mesure de relier ces coordonnées en exprimant les pseudo-distances qui existent entre le capteur GPS et les satellites. Cela se traduit sous la forme suivante :

$$c\Delta t_i(k) = \sqrt{(x(k) - x_i)^2 + (y(k) - y_i)^2 + (z(k) - z_i)^2} . \quad (1.149)$$

où c désigne la célérité à laquelle se propagent les ondes et Δt_i le temps mis par l'onde émise par le $i^{\text{ème}}$ satellite pour atteindre le capteur GPS. Pour obtenir l'écart Δt_i , le satellite qui dispose d'une horloge atomique, communique l'heure exacte à laquelle le signal a été émis.

Cependant, le récepteur a une horloge à quartz moins précise, ce qui génère un biais d'horloge du récepteur GPS, noté $b_i(k)$, par rapport au temps de référence GPS, qu'il est nécessaire d'estimer. Enfin, une perturbation $v(k)$ de nature Gaussienne vient aussi contaminer l'observation. On aboutit donc à l'équation d'observation suivante :

$$c\Delta t_i(k) = \sqrt{(x(k) - x_i)^2 + (y(k) - y_i)^2 + (z(k) - z_i)^2} + b_i(k) + v(k). \quad (1.150)$$

Dans ce cas, on observe que l'équation d'observation reliant les pseudo-distances au vecteur d'état ne se fait pas selon une relation linéaire.

Le GPS étant en mouvement, on fait une hypothèse de mouvement (MRU, MUA, Singer, etc.), ce qui permet d'obtenir l'équation de mise à jour du vecteur d'état.

Remarque :

Aujourd'hui, une précision de 5 à 10 m peut être atteinte. Dans ce fonctionnement nominal, $v(k)$ est supposé Blanc, Gaussien, centré et d'écart type égal à σ_0 (en général fixé à 8m).

³ Le système de coordonnées ECEF est centré sur le centre de masse de la terre. L'axe z est défini comme étant parallèle à l'axe de rotation de la terre, pointant vers le nord. L'axe x a une intersection avec la sphère terrestre au niveau du méridien de Greenwich et l'axe y se trouve dans le plan équatorial.

Cependant, les performances du GPS peuvent être fortement dégradées en présence de multitrajets. Les multi-trajets se produisent quand différentes répliques du signal satellite, issues de réflexions sur les obstacles de l'environnement, parviennent au récepteur. S'il existe un trajet direct entre les satellites et le récepteur, cela se traduit au niveau du bruit de mesure par des sauts de variance.

1.2.12 Exemple n°7 : informations disponibles en traitement radar

En traitement radar, il n'est pas toujours évident de disposer des positions x et y de la cible, mais de la distance d et du gisement θ . Dans ce cas, ce qui lie les coordonnées (x,y) et de la paire (d, θ) est :

$$\begin{cases} x = d \sin(\theta) \\ y = d \cos(\theta) \end{cases} \quad (1.151)$$

Dès lors, la distance s'exprime en fonction de (x,y) comme suit :

$$x^2 + y^2 = d^2 \sin^2(\theta) + d^2 \cos^2(\theta) = d^2. \quad (1.152)$$

De plus, le gisement peut s'écrire de la manière suivante :

$$\theta = \text{Arc tan}\left(\frac{x}{y}\right). \quad (1.153)$$

Dans ce cas, si le vecteur d'état comprend les positions, les vitesses voire les accélérations selon l'axe des x et y , l'équation d'observation est non-linéaire si la distance et le gisement contaminé par une erreur de mesure sont les seules informations disponibles.

1.2.13 Conclusions

La représentation du système dans l'espace d'état est constituée de deux équations : une première équation traduisant la mise à jour du vecteur d'état et une seconde permettant de relier le vecteur d'état aux observations.

Au travers des différents exemples présentés dans les sous sections ci-dessus, nous avons pu montrer comment définir la représentation du système dans l'espace. Nous avons pu observer que cette étape est importante dans la caractérisation du système à étudier. Elle peut aboutir à des situations où les relations sont linéaires ou non-linéaires.

Dans les sections suivantes, nous traitons comment estimer le vecteur d'état à partir des observations bruitées.

1.3 Mise en œuvre du filtre de Kalman

Dans les chapitres précédents, différentes techniques d'identification ont été appliquées à l'estimation de paramètres de modèles linéaires. Nous avons abordé l'étude du filtre de Wiener dans le contexte de l'identification et avons, à cette occasion, mentionné le caractère non récursif de ce filtre. Ici, nous exposons une alternative récursive au filtre de Wiener : celle proposée par Kalman au début des années 60. Kalman y transforme les équations intégrales décrivant le filtre de Wiener dans le cas continu, en équations différentielles.

Cette partie est une introduction au filtre de Kalman. Nous présentons volontairement ce filtre en utilisant une approche algébrique, qui peut certes manquer d'élégance, mais ne nécessite pas de nombreux pré-requis. C'est donc un avantage pour le lecteur isolé ou l'étudiant.

Le filtre de Kalman est présenté, en mettant l'accent sur son utilisation dans le contexte de l'estimation des paramètres de modèles. Nous abordons aussi le filtre de Kalman dit étendu dans le cas d'une estimation non-linéaire.

1.3.1 Formulation du problème

Soit le système représenté dans l'espace d'état par les équations :

$$\underline{x}(k) = \Phi(k-1, k)\underline{x}(k-1) + G(k)\underline{u}(k) \quad (1.154)$$

$$y(k) = H(k)\underline{x}(k) + v(k) \quad (1.155)$$

Le processus générateur $\underline{u}(k)$ et le bruit de mesure $v(k)$ sont supposés de moyenne nulle, c'est-à-dire tels que :

$$E[\underline{u}(k)] = 0 \quad (1.156)$$

$$E[v(k)] = 0 \quad (1.157)$$

De plus, $\underline{u}(k)$ et $v(k)$ sont indépendants, blancs et de matrice de covariance⁴ respectives $Q(k)$ et $R(k)$, soit :

$$E[\underline{u}(k)v^T(l)] = E[\underline{u}(k)]E[v^T(l)] = \underline{0} \quad \forall k, l \quad (1.158)$$

$$E[\underline{u}(k)\underline{u}^T(k)] = Q(k) \quad (1.159)$$

$$E[v(k)v(k)] = R(k). \quad (1.160)$$

Ils satisfont aussi aux conditions suivantes :

$$E[\underline{x}_0(k)\underline{u}^T(k)] = 0 \quad \forall k \geq 0 \quad (1.161)$$

$$E[\underline{x}_0(k)v(k)] = 0 \quad \forall k \geq 0 \quad (1.162)$$

Le problème consiste ici à estimer le vecteur d'état $\underline{x}(k)$, compte tenu des informations disponibles à l'instant n , postérieur, antérieur ou identique à l'instant k . Nous aurons en principe à considérer les trois cas suivants :

1. $k = n$: il s'agit de déterminer une estimation de l'état, compte tenu de toutes les mesures disponibles à l'instant considéré. C'est le cas du *filtrage*.
2. $k < n$: on ne prend ici en compte qu'une partie des mesures disponibles. On fait alors un *lissage* (*smoothing* en anglais) ou une *interpolation*.
3. $k > n$: il s'agit dans ce cas de prédire une estimation du vecteur d'état. C'est ce qu'on appelle de la *prédiction* ou *extrapolation*.

Quel que soit le cas traité, nous notons $\hat{\underline{x}}(k/n)$ l'estimation de l'état $\underline{x}(k)$ à l'instant k , compte tenu des informations disponibles jusqu'à l'instant n .

L'objectif est ici d'obtenir une estimation récursive du vecteur d'état, c'est à dire un algorithme qui à partir d'une estimation du vecteur d'état à l'instant k fournit une nouvelle estimation, si une mesure est disponible à l'instant $k+1$. C'est ce que l'on appelle plus communément le prédictor à un pas.

Pour cela, nous nous intéressons aux étapes dites de prédiction (ou propagation) et de mise à jour, qui correspondent respectivement aux relations entre $\hat{\underline{x}}(k+1/k)$ et $\hat{\underline{x}}(k/k)$ et entre $\hat{\underline{x}}(k/k)$ et $\hat{\underline{x}}(k/k-1)$. De plus, l'obtention des différentes équations qui constituent le filtre

⁴ Comme $\underline{u}(k)$ et le bruit de mesure $v(k)$ sont à moyenne nulle, la matrice de covariance se ramène à la matrice de corrélation.

de Kalman est plus aisée si l'on considère les erreurs d'estimation telles qu'elles se propagent à travers la matrice de covariance de l'erreur.

1.3.2 Etape de prédiction/propagation : relation entre l'estimation *a priori*, $\hat{x}(k/k-1)$, et l'estimation *a posteriori* à l'instant $k-1$, $\hat{x}(k-1/k-1)$, et relation entre $P(k+1/k)$ et $P(k/k)$

Par définition,

$$\hat{x}(k/k-1) = E[\underline{x}(k) | y(1), \dots, y(k-1)] \quad (1.163)$$

Etant donné (1.13), il vient :

$$\hat{x}(k/k-1) = \Phi(k-1, k)E[\underline{x}(k) | y(1), \dots, y(k-1)] + G(k)E[\underline{u}(k) | y(1), \dots, y(k-1)] . \quad (1.164)$$

Comme le bruit de modèle est blanc et centré, il vient :

$$E[\underline{u}(k) | y(1), \dots, y(k-1)] = 0, \quad (1.165)$$

Dès lors, la prédiction du vecteur d'état à l'instant étant donné $k-1$ observations peut se déduire de l'estimation du vecteur d'état à l'instant $k-1$ comme suit :

$$\hat{x}(k/k-1) = \Phi(k-1, k)\hat{x}(k-1/k-1). \quad (1.166)$$

Seule la matrice de transition est dans ce cas nécessaire.

On note alors $\tilde{x}(k/k-1)$ l'erreur d'estimation *a priori* commise sur le vecteur d'état à l'instant k :

$$\tilde{x}(k/k-1) = \underline{x}(k) - \hat{x}(k/k-1). \quad (1.167)$$

La matrice de corrélation de l'erreur *a priori* est définie par :

$$\begin{aligned} P(k/k-1) &= E\left\{[\underline{x}(k) - \hat{x}(k/k-1)][\underline{x}(k) - \hat{x}(k/k-1)]^T\right\} \\ &= E[\tilde{x}(k/k-1)\tilde{x}^T(k/k-1)] \end{aligned} \quad (1.168)$$

De même, on définit l'erreur d'estimation *a posteriori* à l'instant $k-1$ notée $\tilde{x}(k-1/k-1) = \underline{x}(k-1) - \hat{x}(k-1/k-1)$ et sa matrice de covariance comme suit :

$$\begin{aligned} P(k-1/k-1) &= E\left\{[\underline{x}(k-1) - \hat{x}(k-1/k-1)][\underline{x}(k-1) - \hat{x}(k-1/k-1)]^T\right\} \\ &= E[\tilde{x}(k-1/k-1)\tilde{x}^T(k-1/k-1)] \end{aligned} \quad (1.169)$$

A partir des équations d'état (1.13), (1.14) et de la relation linéaire (1.166), explicitons la matrice de corrélation de l'erreur *a priori*. Pour cela, en soustrayant (1.166) à (1.13), il vient :

$$\underline{x}(k) - \hat{x}(k/k-1) = \Phi(k-1, k)[\underline{x}(k-1) - \hat{x}(k-1/k-1)] + G(k)\underline{u}(k) \quad (1.170)$$

Etant donné l'équation (1.170), on en déduit que :

$$\begin{aligned} P(k/k-1) &= \Phi(k-1, k) E\left\{[\underline{x}(k-1) - \hat{x}(k-1/k-1)][\underline{x}(k-1) - \hat{x}(k-1/k-1)]^T\right\} \Phi^T(k-1, k) \\ &\quad + G(k) E[\underline{u}(k)\underline{u}^T(k)] G^T(k) \end{aligned} \quad (1.171)$$

$$\text{soit } P(k/k-1) = \Phi(k-1, k)P(k-1/k-1)\Phi^T(k-1, k) + G(k)Q(k)G^T(k). \quad (1.172)$$

Nous venons ainsi d'établir une première relation récursive entre la matrice de corrélation de l'erreur *a priori* à l'instant k et la matrice de corrélation de l'erreur *a posteriori* à l'instant $k-1$. Cette dernière nécessite la connaissance de la matrice de transition et de la matrice de covariance du bruit de modèle.

1.3.3 Etape de remise à jour : relation entre $\hat{\underline{x}}(k/k)$ et $\hat{\underline{x}}(k/k-1)$ et relation entre $P(k/k)$ et $P(k/k-1)$

A ce stade du développement de l'algorithme, nous abordons le point clef de l'estimation récursive du vecteur d'état. A cet effet, nous adoptons une estimation linéaire du vecteur d'état de la forme :

$$\hat{\underline{x}}(k/k) = \hat{\underline{x}}(k/k-1) + K(k)[y(k) - H(k)\hat{\underline{x}}(k/k-1)] \quad (1.173)$$

L'estimation *a posteriori* du vecteur d'état $\hat{\underline{x}}(k/k)$ correspond à la prédiction $\hat{\underline{x}}(k/k-1)$ modifiée par un terme correctif qui est l'écart pondéré entre la mesure effective et sa prédiction.

Remarque : on retrouve une mise à jour de l'estimation similaire à celle que l'on peut avoir dans le cas de l'algorithme RLS.




Figure 1.2 : **filtrage de Kalman**

$K(k)$ est appelé gain du filtre ou gain de Kalman.

Reprenons l'expression de l'erreur de l'estimation $\tilde{\underline{x}}(k/k)$ et remplaçons l'estimée $\hat{\underline{x}}(k/k)$ par son expression donnée par (1.173) :

$$\begin{aligned} \tilde{\underline{x}}(k/k) &= \underline{x}(k) - \hat{\underline{x}}(k/k) \\ &= \underline{x}(k) - \hat{\underline{x}}(k/k-1) - K(k)[y(k) - H(k)\hat{\underline{x}}(k/k-1)] \\ &= \underline{x}(k) - \hat{\underline{x}}(k/k-1) - K(k)[H(k)\underline{x}(k) + v(k) - H(k)\hat{\underline{x}}(k/k-1)] \\ &= [I - K(k)H(k)][\underline{x}(k) - \hat{\underline{x}}(k/k-1)] - K(k)v(k) \end{aligned} \quad (1.174)$$

où $y(k) - H(k)\hat{\underline{x}}(k/k-1)$ désigne l'innovation. Nous reviendrons sur cette grandeur dans la suite.

On peut alors déduire l'expression de la matrice d'autocorrélation de l'erreur d'estimation *a posteriori* $P(k/k)$ en fonction de $P(k/k-1)$. En effet,

$$\begin{aligned} P(k/k) &= E\left\{ \tilde{\underline{x}}(k/k) \tilde{\underline{x}}^T(k/k) \right\} \\ &= E\left\{ [(I - K(k)H(k))\tilde{\underline{x}}(k/k-1) - K(k)v(k)][(I - K(k)H(k))\tilde{\underline{x}}(k/k-1) - K(k)v(k)]^T \right\} \end{aligned}$$

ou encore :

$$P(k/k) = \left[I - K(k)H(k) \right] P(k/k-1) \left[I - H^T(k)K^T(k) \right] + K(k)R(k)K^T(k) \quad (1.175)$$

Nous avons donc établi une seconde relation réursive entre la matrice de corrélation de l'erreur a posteriori et la matrice de corrélation de l'erreur a priori à l'instant suivant.

1.3.4 Expression du gain du filtre de Kalman

L'objectif est de trouver la valeur du gain $K(k)$ qui minimise l'erreur quadratique moyenne commise sur l'estimation du vecteur d'état. Le critère $J(k)$ à minimiser peut se définir comme suit :

$$J(k) = E \left[\tilde{x}(k/k)^T \tilde{x}(k/k) \right] = \text{trace} \left[E \left(\tilde{x}(k/k) \tilde{x}(k/k)^T \right) \right] = \text{trace} [P(k/k)]. \quad (1.176)$$

Etant donné (1.176) et (1.168), le filtre de Kalman est un filtre à minimum de variance et le gain $K(k)$ minimise donc le critère $J(k)$. Il vérifie donc :

$$\frac{\partial J(k)}{\partial K(k)} = 0 \quad (1.177)$$

Dans cette dernière relation il faut bien noter que l'on calcule une dérivée d'une quantité scalaire $J(k)$ par rapport à un vecteur $K(k)$.

En tenant compte de (1.175), on obtient :

$$\frac{\partial \text{trace} \left\{ \left[I - K(k)H(k) \right] P(k/k-1) \left[I - H^T(k)K^T(k) \right] + K(k)R(k)K^T(k) \right\}}{\partial K(k)} = 0 \quad (1.178)$$

ou encore :

$$P(k/k-1)H^T(k) = K(k)H(k)P(k/k-1)H^T(k) + K(k)R(k); \quad (1.179)$$

d'où :

$$K(k) = P(k/k-1)H^T(k) \left[H(k)P(k/k-1)H^T(k) + R(k) \right]^{-1}. \quad (1.180)$$

Remarque :

Il est à noter que le gain de Kalman s'exprime comme le produit de deux matrices : $\left[H(k)P(k/k-1)H^T(k) + R(k) \right]^{-1}$ est l'inverse de la matrice de corrélation de l'innovation et $P(k/k-1)H^T(k)$ est la matrice d'intercorrélation entre l'innovation et la prédiction du vecteur d'état *a priori*.

En utilisant cette dernière expression, on réécrit la relation (1.175) liant $P(k/k)$ et $P(k/k-1)$, sous la forme :

$$P(k/k) = P(k/k-1) - P(k/k-1)H^T(k) \left[H(k)P(k/k-1)H^T(k) + R(k) \right]^{-1} H(k)P(k/k-1) \quad (1.181)$$

ou encore :

$$P(k/k) = \left[I - K(k)H(k) \right] P(k/k-1) \quad (1.182)$$

Dans le cas continu, l'équation (1.181) prend la forme d'une équation différentielle dite de Ricatti. C'est pour cette raison, et par analogie, que la relation (1.181) est appelée ici équation de Ricatti discrète.

Une autre expression du gain de Kalman peut être obtenue et repose sur l'application du lemme d'inversion matricielle à la relation (1.182). Il vient :

$$P^{-1}(k/k) = P^{-1}(k/k-1) - P^{-1}(k/k-1)K(k)[I - H(k)K(k)]^{-1}H(k). \quad (1.183)$$

Remplaçons le gain de Kalman par son expression donnée en (1.180), on obtient :

$$\begin{aligned} P^{-1}(k/k) &= P^{-1}(k/k-1) \\ &\quad - P^{-1}(k/k-1)P(k/k-1)H^T(k)\left[H(k)P(k/k-1)H^T(k) + R(k)\right]^{-1} \\ &\quad \left[I - H(k)P(k/k-1)H^T(k)\left[H(k)P(k/k-1)H^T(k) + R(k)\right]^{-1}\right]^{-1}H(k) \end{aligned} \quad (1.184)$$

ou :

$$P^{-1}(k/k) = P^{-1}(k/k-1) - H^T(k)R^{-1}(k)H(k) \quad (1.185)$$

à condition que $R(k)$ soit inversible.

Les produits $P(k/k)P^{-1}(k/k)$ et $R(k)R^{-1}(k)$ étant égaux à la matrice identité I , on peut les insérer dans l'expression du gain, soit :

$$\begin{aligned} K(k) &= P(k/k)P^{-1}(k/k)P(k/k-1)H^T(k)R(k)R^{-1}(k)\left[H(k)P(k/k-1)H^T(k) + R(k)\right]^{-1} \\ &= P(k/k)P^{-1}(k/k)P(k/k-1)H^T(k)R^{-1}(k)\left[H(k)P(k/k-1)H^T(k)R^{-1}(k) + I\right]^{-1} \end{aligned} \quad (1.186)$$

Nous remplaçons alors dans cette dernière relation $P^{-1}(k/k)$ par sa valeur donnée dans la relation (1.185), il vient :

$$\begin{aligned} K(k) &= P(k/k)H^T(k)R^{-1}(k)\left[I + H(k)P(k/k-1)H^T(k)R^{-1}(k)\right] \\ &\quad \left[H(k)P(k/k-1)H^T(k)R^{-1}(k) + I\right]^{-1} \end{aligned} \quad (1.187)$$

soit :

$$K(k) = P(k/k)H^T(k)R^{-1}(k). \quad (1.188)$$

Remarque 1 :

La quantité $P(k/k)$ traduit la confiance que nous pouvons avoir dans le modèle adopté.

Remarque 2 :

Reprenons la relation

$$\hat{x}(k/k) = \hat{x}(k/k-1) + K(k)[y(k) - H(k)\hat{x}(k/k-1)] \quad (1.173)$$

en écrivant différemment l'innovation, on obtient :

$$\begin{aligned} \hat{x}(k/k) &= \hat{x}(k/k-1) + K(k)[H(k)x(k) + v(k) - H(k)\hat{x}(k/k-1)] \\ &= \hat{x}(k/k-1) + K(k)[H(k)\tilde{x}(k/k-1) + v(k)] \end{aligned} \quad (1.189)$$

Nous allons effectuer un raisonnement qualitatif pour mettre en évidence la signification de chacun des termes de la relation (1.173).

Etant donné les expressions du gain de Kalman que nous venons de présenter, il apparaît que :

- A $R(k)$ constant, si $P(k/k)$ est faible, le gain ne sera pas trop grand. On fera ainsi davantage confiance en l'estimation obtenue à partir du modèle. En revanche si $P(k/k)$ est élevée, ce qui traduit notre faible confiance dans le domaine, le gain sera plus élevé et la contribution du terme de correction pondéré par le gain sera plus forte. Certains disent que « l'on a confiance dans la mesure ».
- A $P(k/k)$ constant, si $R(k)$ est faible, les mesures seront faiblement bruitées. La valeur du gain donnera plus de poids à la mesure. Si $R(k)$ est élevée, le gain sera plus faible et le poids du second terme dans (1.173) sera moins grand.

Remarque 3 :

Il a été montré que le gain optimal du filtre de Kalman ne minimise pas uniquement la trace de la matrice de covariance de l'erreur, mais toute combinaison linéaire des éléments diagonaux de cette matrice. De ce résultat, on peut conclure qu'il n'y a pas lieu, dans le cas où le vecteur d'état contient des quantités physiques ayant des dimensions différentes (vitesse, position, etc.) de se préoccuper de la signification physique à donner à la somme des erreurs associées à ces quantités.

1.3.5 Initialisation et mise en œuvre du filtre

Pour pouvoir utiliser l'ensemble des équations récurrentes constituant le filtre de Kalman, on doit choisir les conditions initiales de l'estimation du vecteur d'état $\hat{x}(0/0)$ et de la matrice de covariance de l'erreur correspondante $P(0/0)$. Si l'on ne dispose d'aucune information *a priori*, on adopte pour l'initialisation du vecteur d'état :

$$\hat{x}(0/0) = E[x(0)]. \quad (1.190)$$

Si la connaissance de $E[x(0)]$ fait défaut, on la prend égale à zéro :

$$P(0/0) = P(0) = E\{[x(0) - \hat{x}(0/0)][x(0) - \hat{x}(0/0)]^T\} \quad (1.191)$$

Remarque :

Si nous reprenons les expressions des matrices de covariance d'erreur *a priori* et *a posteriori*, respectivement $P(k/k-1)$ et $P(k/k)$ et du gain $K(k)$, il vient :

$$P(k/k-1) = \Phi(k, k-1)P(k-1/k-1)\Phi^T(k, k-1) + G(k-1)Q(k-1)G^T(k-1) \quad (1.192)$$

$$K(k) = P(k/k-1)H^T(k)[H(k)P(k/k-1)H^T(k) + R(k)]^{-1} \quad (1.193)$$

$$P(k/k) = [I - K(k)H(k)]P(k/k-1) \quad (1.194)$$

Il apparaît que l'on peut déterminer ces trois quantités indépendamment de toute mesure et avant même que celle-ci ne soit traitée par le filtre.

Ces quantités peuvent être déterminées dans l'ordre où elles sont écrites. On a besoin pour ce faire de la connaissance de $P(0/0)$.

Le déroulement des différentes opérations peut être décomposé comme suit :

✓ pour $k=1$ on calcule successivement :

$$P(1/0) \text{ avec } P(1/0) = \Phi(1,0)P(0/0)\Phi^T(1,0) + G(0)Q(0)G^T(0)$$

$$K(1) \text{ avec } K(1) = P(1/0)H^T(1)[H(1)P(1/0)H^T(1) + R(1)]^{-1}$$

$$\hat{x}(1/0) \text{ avec } \hat{x}(1/0) = \Phi(1,0)\hat{x}(0/0)$$

$$\hat{x}(1/1) \text{ avec } \hat{x}(1/1) = \hat{x}(1/0) + K(1)[y(1) - H(1)\hat{x}(1/0)]$$

- ✓ pour $k = 2$, on procède de la même manière à la remise à jour des estimations du vecteur d'état *a priori* et *a posteriori*. Et ainsi de suite.

Le choix des valeurs initiales est délicat pour assurer une convergence rapide de l'algorithme, mais un mauvais choix de $\hat{x}(0/0)$, c'est-à-dire, à la limite, une valeur arbitraire n'est pas catastrophique en ce sens que l'algorithme excité par les mesures apportera les corrections nécessaires. Par contre, le traitement des mesures n'améliore pas la covariance de l'erreur au fur et à mesure de son traitement. Nous pouvons traduire notre ignorance de $P(0/0)$ en adoptant $P(0/0) = \alpha I$, avec α de valeur élevée.




Figure 1.3 : **organigramme du filtre de Kalman**

Remarque 1 :

Reprenons l'équation (1.188) qui lie $P(k/k)$ à $P(k/k-1)$:

$$P(k/k) = [I - K(k)H(k)]P(k/k-1) \quad (1.195)$$

Nous avons que le filtre de Kalman repose sur l'introduction d'un gain qui minimise le gain $J(k)$ défini comme suit :

$$J(k) = \text{trace} \left[P(k/k) \right]. \quad (1.196)$$

En combinant (1.188) et (1.176), on constate que :

$$\text{trace} \left[P(k/k) \right] = \text{trace} \left[P(k/k-1) \right] - \text{trace} \left[K(k)H(k)P(k/k) \right]. \quad (1.197)$$

Or, la matrice $K(k)H(k)P(k/k)$ est définie positive ou à la rigueur semi-définie positive. Il s'en suit que tous ses éléments seront soit positifs, soit nuls. Dès lors, on aboutit à l'inégalité suivante :

$$\text{trace} \left[P(k/k) \right] < \text{trace} \left[P(k/k-1) \right]. \quad (1.198)$$

Ainsi, l'erreur d'estimation ne peut que diminuer au fur et à mesure que l'algorithme se déroule.

1.3.6 Notions d'innovation

Reprenons l'équation de l'estimateur récursif :

$$\hat{\underline{x}}(k/k) = \hat{\underline{x}}(k/k-1) + K(k) [y(k) - H(k) \hat{\underline{x}}(k/k-1)] \quad (1.199)$$

Si cette prédiction est parfaite, en absence du bruit de mesure, la correction apportée par la quantité $e(k)$, que l'on appelle l'innovation, est nulle :

$$e(k) = y(k) - H(k) \hat{\underline{x}}(k/k-1) = 0 \quad (1.200)$$

Il s'agit d'un raisonnement quantitatif.

On peut en outre montrer que, si le filtre est optimal, le processus d'innovation $e(k)$ est une séquence blanche de valeur moyenne nulle, c'est-à-dire, qu'il ne contient plus d'informations pouvant enrichir la mise à jour de l'estimation de l'état. En testant la « blanché » de l'innovation on peut apprécier le degré d'optimalité et donc les performances du filtre. C'est ainsi que Mehra, en utilisant N mesures de l'innovation, a suggéré le test statistique suivant :

$$|\hat{r}_{ee}(j)| \leq \frac{1.95 \hat{r}_{ee}(0)}{\sqrt{N}} \text{ pour } j > 0 \quad (1.201)$$

où par $\hat{r}_{ee}(j)$ nous avons noté l'estimé de l'autocorrélation de l'innovation.

On peut utiliser le test proposé par Stoica :

$$\sum_{i=1}^j \hat{r}_{ee}^2(i) \leq (j+1.65\sqrt{2j}) \hat{r}_{ee}^2(0)/N \quad (1.202)$$

Bien entendu, il existe d'autres tests de blanché.

Remarque :

Les performances du filtre de Kalman peuvent se dégrader et le filtre risque de diverger si la dynamique du processus générateur n'est pas Gaussienne.

1.3.7 Approche alternative

Bien que l'approche de Kalman consiste à estimer le vecteur d'état au sens des moindres carrés à partir des observations disponibles, on peut obtenir les mêmes équations au travers d'une approche bayésienne.

Ainsi, reprenons l'équation de mise à jour du vecteur d'état suivante :

$$\underline{x}(k) = \Phi(k-1, k) \underline{x}(k-1) + G(k) \underline{u}(k) \quad (1.203)$$

et l'équation d'observation suivante :

$$y(k) = H(k) \underline{x}(k) + v(k) \quad (1.204)$$

Le modèle dynamique étant supposé markovien d'ordre 1, la valeur du vecteur d'état à l'instant k dépend uniquement de celle à l'instant précédent et est indépendante des mesures passées. On a donc :

$$p(\underline{x}(k) / \underline{x}(1), \dots, \underline{x}(k-1), y(1), \dots, y(k-1)) = p(\underline{x}(k) / \underline{x}(k-1)) \quad (1.205)$$

De plus, l'observation $y(k)$ étant donné la valeur de $\underline{x}(k)$ est conditionnellement indépendante des observations passées et des valeurs prises par le vecteur d'état. On a donc :

$$p(y(k) / \underline{x}(1), \dots, \underline{x}(k), y(1), \dots, y(k-1)) = p(y(k) / \underline{x}(k)) \quad (1.206)$$

La relation (1.203) revient à dire que la valeur $\underline{x}(k)$ prise par le vecteur d'état à l'instant k étant donné celle à l'instant $k-1$ dépend uniquement de $G(k) \underline{u}(k)$. Comme $\underline{u}(k)$ est Gaussien de moyenne nulle et de matrice de covariance $Q(k)$, la loi dite de transition $p(\underline{x}(k) / \underline{x}(k-1))$

s'exprime comme une loi Gaussienne de moyenne $\Phi(k-1, k)\underline{x}(k-1)$ et de matrice de covariance $G(k)Q(k)G^T(k)$. Si le vecteur d'état comprend n variables d'état réelles, la loi satisfait :

$$p(\underline{x}(k) / \underline{x}(k-1)) = \frac{1}{(2\pi)^{n/2} |G(k)Q(k)G^T(k)|^{1/2}} \times \exp\left(-\frac{1}{2}(\underline{x}(k) - \Phi(k-1, k)\underline{x}(k-1))^T [G(k)Q(k)G^T(k)]^{-1} (\underline{x}(k) - \Phi(k-1, k)\underline{x}(k-1))\right) \quad (1.207)$$

où $|G(k)Q(k)G^T(k)|$ désigne le déterminant de la matrice de covariance $G(k)Q(k)G^T(k)$.

Quant à la relation (1.204), elle revient à dire que la valeur prise par l'observation, à l'instant k étant donné la valeur prise par le vecteur d'état à l'instant k dépend uniquement du bruit de mesure $v(k)$. Comme $v(k)$ est un bruit blanc Gaussien centré de variance $R(k)$, la vraisemblance $p(y(k) / \underline{x}(k))$ est une loi Gaussienne de moyenne $H(k)\underline{x}(k)$ et variance $R(k)$, soit :

$$p(y(k) / \underline{x}(k)) = \frac{1}{(2\pi)^{1/2} \sqrt{R(k)}} \exp\left(-\frac{1}{2}(y(k) - H(k)\underline{x}(k))^T R^{-1}(k)(y(k) - H(k)\underline{x}(k))\right) \quad (1.208)$$

Or, on rappelle que l'on cherche à obtenir de manière récursive une estimation du vecteur d'état :

$$\hat{\underline{x}}(k/k) = E\left[\underline{x}(k) \middle| y(1), \dots, y(k)\right] = \int \underline{x}_k p(\underline{x}_k / y(1), \dots, y(k)) d\underline{x}_k \quad (1.209)$$

où $p(\underline{x}_k / y(1), \dots, y(k))$ désigne la distribution *a posteriori* de l'état connaissant les mesures jusqu'à l'instant k .

Dans la suite exprimons $p(\underline{x}_k / y(1), \dots, y(k))$ en fonction de la loi de transition et de la vraisemblance. Nous opérons en deux étapes : une étape de prédiction puis une étape de filtrage.

En exprimant la distribution *a priori* de l'état connaissant les mesures jusqu'à l'instant $k-1$, notée $p(\underline{x}(k) / y(1), \dots, y(k-1))$, l'étape de prédiction peut se formuler sous la forme suivante :

$$p(\underline{x}_k / y(1), \dots, y(k-1)) = \int p(\underline{x}_k, \underline{x}_{k-1} / y(1), \dots, y(k-1)) d\underline{x}_{k-1} \quad (1.210)$$

Cela revient à dire que la distribution marginale de $\underline{x}_k$ étant donné les observations $\{y(1), \dots, y(k-1)\}$, à savoir $p(\underline{x}_k / y(1), \dots, y(k-1))$, se déduit en sommant $p(\underline{x}_k, \underline{x}_{k-1} / y(1), \dots, y(k-1))$ sur l'ensemble des valeurs $\underline{x}_{k-1}$.

Pour cela, exprimons $p(\underline{x}_k, \underline{x}_{k-1} / y(1), \dots, y(k-1))$ par la formule de Bayes ; il vient :

$$\begin{aligned} p(\underline{x}_k, \underline{x}_{k-1} / y(1), \dots, y(k-1)) &= p(\underline{x}_k / \underline{x}_{k-1}, y(1), \dots, y(k-1)) p(\underline{x}_{k-1} / y(1), \dots, y(k-1)) \\ &= p(\underline{x}_k / \underline{x}_{k-1}) p(\underline{x}_{k-1} / y(1), \dots, y(k-1)) \end{aligned} \quad (1.211)$$

Dans le cas présent, $p(x_k / x_{k-1})$ est une distribution Gaussienne de moyenne $\Phi(k-1, k)x_{k-1}$ et de matrice de covariance $G(k)Q(k)G^T(k)$ alors que $p(x_{k-1} / y(1), \dots, y(k-1))$ est Gaussienne de moyenne $\hat{x}(k-1/k-1)$ et de matrice de covariance $P(k-1/k-1)$. On peut montrer que $p(x_{k-1}, x_k / y(1), \dots, y(k-1))$ est aussi une loi Gaussienne de moyenne $\begin{bmatrix} \hat{x}(k-1/k-1) & \Phi(k-1, k)\hat{x}(k-1/k-1) \end{bmatrix}$ et de matrice de covariance :

$$\begin{bmatrix} P(k-1/k-1) & P(k-1/k-1)\Phi^T(k-1, k) \\ \Phi(k-1, k)P(k-1/k-1) & \Phi(k-1, k)P(k-1/k-1)\Phi^T(k-1, k) + G(k)Q(k)G^T(k) \end{bmatrix}$$

La distribution $p(x(k) / y(1), \dots, y(k-1))$ est alors une Gaussienne de moyenne $\hat{x}(k/k-1) = \Phi(k-1, k)\hat{x}(k-1/k-1)$ et de matrice de covariance $P(k/k-1) = \Phi(k-1, k)P(k-1/k-1)\Phi^T(k-1, k) + G(k)Q(k)G^T(k)$.

Puis, l'étape de mise à jour repose sur la règle de Bayes et permet d'aboutir à la relation suivante :

$$\begin{aligned} p(y(k), x_k / y(1), \dots, y(k-1)) &= p(x_k / y(1), \dots, y(k))p(y(k) / y(1), \dots, y(k-1)) \\ &= p(y(k) / x_k, y(1), \dots, y(k-1))p(x_k / y(1), \dots, y(k-1)) \\ &= p(y(k) / x_k)p(x_k / y(1), \dots, y(k-1)) \end{aligned} \quad (1.212)$$

Dès lors, étant la relation (1.212), on obtient :

$$\begin{aligned} p(x_k / y(1), \dots, y(k)) &= \frac{1}{p(y(k) / y(1), \dots, y(k-1))} p(y(k) / x_k, y(1), \dots, y(k-1))p(x_k / y(1), \dots, y(k-1)) \\ &= \frac{p(y(k) / x_k)p(x_k / y(1), \dots, y(k-1))}{p(y(k) / y(1), \dots, y(k-1))} \end{aligned} \quad (1.213)$$

Remarque :

On peut aussi écrire cette dernière relation comme suit :

$$\begin{aligned} p(x_k / y(1), \dots, y(k)) &= \frac{1}{\int p(y(k) / x_k)p(x_k / y(1), \dots, y(k-1))dx_k} p(y(k) / x_k)p(x_k / y(1), \dots, y(k-1)) \end{aligned} \quad (1.214)$$

La distribution marginale de $y(k)$ étant donné les observations $\{y(1), \dots, y(k-1)\}$, à savoir $p(y(k) / y(1), \dots, y(k-1))$, peut alors se déduire en sommant $p(y(k), x_k / y(1), \dots, y(k-1))$ sur l'ensemble des valeurs x_k .

D'après (1.212) et dans le cas présent, $p(y(k) / x_k)$ est Gaussienne de moyenne $H(k)x_k$ et de matrice de covariance $R(k)$ alors que $p(x_k / y(1), \dots, y(k-1))$ a été définie plus haut. On peut montrer que $p(y(k), x_k / y(1), \dots, y(k-1))$ est aussi une loi Gaussienne de moyenne $\begin{bmatrix} \hat{x}(k/k-1) & H(k)\hat{x}(k/k-1) \end{bmatrix}$ et de matrice de covariance :

$$\begin{bmatrix} P(k/k-1) & P(k/k-1)H^T(k) \\ H(k)P(k/k-1) & H(k)P(k/k-1)H^T(k) + R(k) \end{bmatrix}$$

La distribution $p(\underline{x}(k) / y(1), \dots, y(k))$ est alors une Gaussienne de moyenne $\hat{\underline{x}}(k/k) = \hat{\underline{x}}(k/k-1) + P(k/k-1)H^T(k)[H(k)P(k/k-1)H^T(k) + R(k)]^{-1}[y(k) - H(k)\hat{\underline{x}}(k/k-1)]$ et de matrice de covariance :

$$P(k/k) = P(k/k-1) - P(k/k-1)H^T(k)[H(k)P(k/k-1)H^T(k) + R(k)]^{-1}H(k)P(k/k-1).$$

Equation du modèle	$\underline{x}(k+1) = \Phi(k+1, k)\underline{x}(k) + G(k)\underline{u}(k)$
Equation d'observation	$y(k) = H(k)\underline{x}(k) + v(k)$
Information <i>a priori</i>	$E[\underline{u}(k)] = 0$ et $E[v(k)] = 0$ $E[\underline{u}(k)v(l)] = 0 \quad \forall k, l$ $E[\underline{u}(k)\underline{u}^T(l)] = Q(k)\delta(k-l)$ $E[v(k)v(l)] = R(k)\delta(k-l)$ $E[\underline{x}_0(k)\underline{u}^T(k)] = 0 \quad \forall k \geq 0$ $E[\underline{x}_0(k)v(k)] = 0 \quad \forall k \geq 0$
Equations du filtre	$\hat{\underline{x}}(k/k-1) = \Phi(k, k-1)\hat{\underline{x}}(k-1/k-1)$ $\hat{\underline{x}}(k/k) = \hat{\underline{x}}(k/k-1) + K(k)[y(k) - H(k)\hat{\underline{x}}(k/k-1)]$
Expressions du gain	$K(k) = P(k/k-1)H^T(k)[H(k)P(k/k-1)H^T(k) + R(k)]^{-1}$ $K(k) = P(k/k)H^T(k)R^{-1}(k)$
Variance <i>a posteriori</i>	$P(k/k) = [I - K(k)H(k)]P(k/k-1)$
Variance <i>a priori</i>	$P(k/k-1) = \Phi(k-1, k)P(k-1/k-1)\Phi^T(k-1, k)$ $+ G(k)Q(k)G^T(k)$
Conditions initiales	$\hat{\underline{x}}(0/0) = E[\underline{x}(0)]$ $P(0/0) = P(0) = E\{[\underline{x}(0) - \hat{\underline{x}}(0/0)][\underline{x}(0) - \hat{\underline{x}}(0/0)]^T\}$

1.4 Mise en œuvre du filtre de Kalman étendu

Soit le système représenté dans l'espace d'état par les équations :

$$\underline{x}(k) = f(\underline{x}(k-1)) + G(k)\underline{u}(k) \quad (1.215)$$

$$y(k) = g(\underline{x}(k)) + v(k) \quad (1.216)$$

où f et g sont des fonctions non-linéaires.

L'objet du filtre de Kalman étendu est d'utiliser une linéarisation au premier ordre des fonctions non-linéaires f et g et de se ramener aux équations du filtre de Kalman standard.

Ainsi, considérons le développement de Taylor au premier ordre de la fonction non-linéaire de mise à jour du vecteur d'état autour de la dernière estimation disponible du vecteur d'état, à savoir $\hat{\underline{x}}(k-1/k-1)$. On a alors :

$$\begin{aligned}\underline{x}(k) &= f(\underline{x}(k-1)) + G(k)\underline{u}(k) \\ &\approx f(\hat{\underline{x}}(k-1/k-1)) + \nabla_f(x) \Big|_{x=\hat{\underline{x}}(k-1/k-1)} (\underline{x}(k-1) - \hat{\underline{x}}(k-1/k-1)) + G(k)\underline{u}(k)\end{aligned}\quad (1.217)$$

où $\nabla_f(x) \Big|_{x=\hat{\underline{x}}(k-1/k-1)}$ est la matrice Jacobienne de f calculée au point $\hat{\underline{x}}(k-1/k-1)$.

Etant donné (1.163), exprimons une estimation du vecteur d'état $\underline{x}(k)$ à partir de $k-1$ observations bruitées, en tirant profit que l'espérance mathématique est un opérateur linéaire :

$$\begin{aligned}\hat{\underline{x}}(k/k-1) &= E[\underline{x}(k) | y(1), \dots, y(k-1)] \\ &\approx f(\hat{\underline{x}}(k-1/k-1)) + \nabla_f(x) \Big|_{x=\hat{\underline{x}}(k-1/k-1)} (E[\underline{x}(k-1) | y(1), \dots, y(k-1)] - \hat{\underline{x}}(k-1/k-1)) \\ &\quad + G(k)E[\underline{u}(k) | y(1), \dots, y(k-1)] \\ &\approx f(\hat{\underline{x}}(k-1/k-1)) + \nabla_f(x) \Big|_{x=\hat{\underline{x}}(k-1/k-1)} (\hat{\underline{x}}(k-1/k-1) - \hat{\underline{x}}(k-1/k-1)) \\ &\approx f(\hat{\underline{x}}(k-1/k-1))\end{aligned}\quad (1.218)$$

Dans le cas non-linéaire, la prédiction du vecteur d'état satisfait nécessite la fonction non-linéaire f alors que dans le cas linéaire, la mise à jour du vecteur d'état est de la forme :

$$\hat{\underline{x}}(k/k-1) = \Phi(k-1, k)\hat{\underline{x}}(k-1/k-1). \quad (1.219)$$

Regardons à présent l'erreur d'estimation *a priori* du vecteur d'état. En faisant la différence terme à terme des équations (1.217) et (1.218), on aboutit à :

$$\begin{aligned}\tilde{\underline{x}}(k/k-1) &= \underline{x}(k) - \hat{\underline{x}}(k/k-1) \\ &\approx f(\hat{\underline{x}}(k-1/k-1)) + \nabla_f(x) \Big|_{x=\hat{\underline{x}}(k-1/k-1)} (\underline{x}(k-1) - \hat{\underline{x}}(k-1/k-1)) + G(k)\underline{u}(k) \\ &\quad - f(\hat{\underline{x}}(k-1/k-1)) \\ &\approx \nabla_f(x) \Big|_{x=\hat{\underline{x}}(k-1/k-1)} (\underline{x}(k-1) - \hat{\underline{x}}(k-1/k-1)) + G(k)\underline{u}(k)\end{aligned}\quad (1.220)$$

En comparant (1.220) et (1.170), on peut constater que la Jacobienne de f joue le même rôle dans le cas de l'EKF que la matrice de transition dans le cas du filtre de Kalman standard.

Intéressons-nous à présent à l'innovation et effectuons un développement de Taylor au premier ordre de g autour de la dernière estimation du vecteur d'état disponible, à savoir $\hat{\underline{x}}(k/k-1)$:

$$\begin{aligned}y(k) - g(\hat{\underline{x}}(k/k-1)) &= g(\underline{x}(k)) + v(k) - g(\hat{\underline{x}}(k/k-1)) \\ &= g(\hat{\underline{x}}(k/k-1)) + \nabla_g(x) \Big|_{x=\hat{\underline{x}}(k/k-1)} (\underline{x}(k) - \hat{\underline{x}}(k/k-1)) + v(k) - g(\hat{\underline{x}}(k/k-1)) \\ &= \nabla_g(x) \Big|_{x=\hat{\underline{x}}(k/k-1)} (\underline{x}(k) - \hat{\underline{x}}(k/k-1)) + v(k) \\ &= \nabla_g(x) \Big|_{x=\hat{\underline{x}}(k/k-1)} \tilde{\underline{x}}(k/k-1) + v(k)\end{aligned}\quad (1.221)$$

où $\nabla_g(x) \Big|_{x=\hat{\underline{x}}(k/k-1)}$ désigne la Jacobienne de la fonction g , calculée au point $\hat{\underline{x}}(k/k-1)$

En comparant (1.189) et (1.221), on peut constater que la Jacobienne de g joue le même rôle dans le cas de l'EKF que le vecteur d'observation dans le cas du filtre de Kalman standard.

Equation du modèle	$\underline{x}(k) = f(\underline{x}(k-1)) + G(k)\underline{u}(k)$
Equation d'observation	$y(k) = g(\underline{x}(k)) + v(k)$
Information <i>a priori</i>	$E[\underline{u}(k)] = 0$ et $E[v(k)] = 0$ $E[\underline{u}(k)v(l)] = 0 \quad \forall k, l$ $E[\underline{u}(k)\underline{u}^T(l)] = Q(k)\delta(k-l)$ $E[v(k)v(l)] = R(k)\delta(k-l)$ $E[\underline{x}_0(k)\underline{u}^T(k)] = 0 \quad \forall k \geq 0$ $E[\underline{x}_0(k)v(k)] = 0 \quad \forall k \geq 0$
Equations du filtre	$\hat{\underline{x}}(k/k-1) \approx f(\hat{\underline{x}}(k-1/k-1))$ $\hat{\underline{x}}(k/k) = \hat{\underline{x}}(k/k-1) + K(k)[y(k) - f(\hat{\underline{x}}(k/k-1))]$
Expressions du gain	$K(k) = P(k/k-1)\nabla_g^T(x)\Big _{x=\hat{\underline{x}}(k/k-1)}$ $\left[\nabla_g(x)\Big _{x=\hat{\underline{x}}(k/k-1)} P(k/k-1)\nabla_g^T(x)\Big _{x=\hat{\underline{x}}(k/k-1)} + R(k) \right]^{-1}$
Variance <i>a posteriori</i>	$P(k/k) = \left[I - K(k)\nabla_g(x)\Big _{x=\hat{\underline{x}}(k/k-1)} \right] P(k/k-1)$
Variance <i>a priori</i>	$P(k/k-1) = \nabla_f(x)\Big _{x=\hat{\underline{x}}(k-1/k-1)} P(k-1/k-1)\nabla_f^T(x)\Big _{x=\hat{\underline{x}}(k-1/k-1)}$ $+ G(k)Q(k)G^T(k)$
Conditions initiales	$\hat{\underline{x}}(0/0) = E[\underline{x}(0)]$ $P(0/0) = P(0) = E\{[\underline{x}(0) - \hat{\underline{x}}(0/0)][\underline{x}(0) - \hat{\underline{x}}(0/0)]^T\}$

De temps à temps, le filtre EKF peut diverger si l'approximation au premier ordre ne suffit pas pour décrire la non-linéarité. Pour cette raison, un développement de Taylor au second ordre peut être envisagé et aboutit au filtre de Kalman étendu du 2nd ordre.

1.5 Mise en œuvre du filtre de Kalman étendu itératif

Le filtre de Kalman étendu itératif est une alternative au filtre EKF qui vise à améliorer les performances de l'EKF, notamment en terme de vitesse de convergence. Le principe de l'IEKF est de linéariser le modèle de mesure autour du vecteur d'état remis à jour au lieu du vecteur d'état prédit. Pour cela, on opère de façon itérative. Ainsi à la $i^{\text{ème}}$ itération à l'instant k , on a :

Equation du modèle	$\underline{x}(k) = f(\underline{x}(k-1)) + G(k)\underline{u}(k)$
Equation d'observation	$y(k) = g(\underline{x}(k)) + v(k)$
Information <i>a priori</i>	$E[\underline{u}(k)] = 0$ et $E[v(k)] = 0$ $E[\underline{u}(k)v(l)] = 0 \quad \forall k, l$ $E[\underline{u}(k)\underline{u}^T(l)] = Q(k)\delta(k-l)$

	$E[v(k)v(l)] = R(k)\delta(k-l)$ $E[\underline{x}_0(k)\underline{u}^T(k)] = 0 \quad \forall k \geq 0$ $E[\underline{x}_0(k)v(k)] = 0 \quad \forall k \geq 0$
Equations du filtre	$\hat{\underline{x}}(k/k-1) \approx f(\hat{\underline{x}}(k-1/k-1))$ A la $i^{\text{ème}}$ itération, avec i initialisé à la valeur 1. $\hat{\underline{x}}_{i+1}(k/k) = \hat{\underline{x}}(k/k-1) + K_i(k)[y(k) - f(\hat{\underline{x}}(k/k-1))]$ Cette démarche itérative s'arrête quand $ \hat{\underline{x}}_{i+1}(k/k) - \hat{\underline{x}}_i(k/k) < \varepsilon I_L \text{ avec } \varepsilon \text{ petit.}$
Expressions du gain	$K_i(k) = P(k/k-1) \nabla_g^T(x) \Big _{x=\hat{\underline{x}}_i(k/k)}$ $\left[\nabla_g(x) \Big _{x=\hat{\underline{x}}_i(k/k)} P(k/k-1) \nabla_g^T(x) \Big _{x=\hat{\underline{x}}_i(k/k)} + R(k) \right]^{-1}$ avec $\hat{\underline{x}}_1(k/k) = \hat{\underline{x}}(k/k-1)$
Variance <i>a posteriori</i>	$P(k/k) = \left[I - K(k) \nabla_g(x) \Big _{x=\hat{\underline{x}}_i(k/k)} \right] P(k/k-1)$ avec $\hat{\underline{x}}_1(k/k) = \hat{\underline{x}}(k/k-1)$
Variance <i>a priori</i>	$P(k/k-1) = \nabla_f(x) \Big _{x=\hat{\underline{x}}(k-1/k-1)} P(k-1/k-1) \nabla_f^T(x) \Big _{x=\hat{\underline{x}}(k-1/k-1)} + G(k)Q(k)G^T(k)$
Conditions initiales	$\hat{\underline{x}}(0/0) = E[\underline{x}(0)]$ $P(0/0) = P(0) = E\{[\underline{x}(0) - \hat{\underline{x}}(0/0)][\underline{x}(0) - \hat{\underline{x}}(0/0)]^T\}$

1.6 Mise en œuvre du filtre de Kalman étendu du second ordre

Au lieu d'effectuer un développement de Taylor du premier ordre autour de la dernière estimation du vecteur d'état disponible, considérons un développement de Taylor du deuxième ordre. Il vient :

$$\begin{aligned}
\underline{x}(k) &= f(\underline{x}(k-1)) + G(k)\underline{u}(k) \\
&\approx f(\hat{\underline{x}}(k-1/k-1)) + \nabla_f(x) \Big|_{x=\hat{\underline{x}}(k-1/k-1)} (\underline{x}(k-1) - \hat{\underline{x}}(k-1/k-1)) + \frac{1}{2} \Phi(k) \\
&\quad + G(k)\underline{u}(k)
\end{aligned} \tag{1.222}$$

avec

$$\begin{aligned}
\Phi(k) &= \sum_{l=1}^L \left[\underbrace{0 \cdots 0}_{l-1} \quad 1 \quad \underbrace{0 \cdots 0}_{L-l} \right]^T \\
&\quad \times (\underline{x}(k-1) - \hat{\underline{x}}(k-1/k-1))^T \frac{\partial^2 f_l(x)}{\partial x^2} \bigg|_{\hat{\underline{x}}(k-1/k-1)} (\underline{x}(k-1) - \hat{\underline{x}}(k-1/k-1)) \quad (1.223) \\
&= \sum_{l=1}^L \left[\underbrace{0 \cdots 0}_{l-1} \quad 1 \quad \underbrace{0 \cdots 0}_{L-l} \right]^T \Phi_l(k)
\end{aligned}$$

où $\frac{\partial^2 f_l(x)}{\partial x^2} \bigg|_{\hat{\underline{x}}(k-1/k-1)}$ dénote la dérivée seconde de la fonction non-linéaire f par rapport à la $l^{\text{ème}}$

composante du vecteur d'état et évaluée en $\hat{\underline{x}}(k-1/k-1)$.

Il est à noter que le $l^{\text{ème}}$ terme quadratique $\Phi_l(k)$ peut aussi s'exprimer comme suit :

$$\begin{aligned}
\Phi_l(k) &= (\underline{x}(k-1) - \hat{\underline{x}}(k-1/k-1))^T \frac{\partial^2 f_l(x)}{\partial x^2} \bigg|_{\hat{\underline{x}}(k-1/k-1)} (\underline{x}(k-1) - \hat{\underline{x}}(k-1/k-1)) \\
&= \frac{\partial^2 f_l(x)}{\partial x^2} \bigg|_{\hat{\underline{x}}(k-1/k-1)} (\underline{x}(k-1) - \hat{\underline{x}}(k-1/k-1))^T (\underline{x}(k-1) - \hat{\underline{x}}(k-1/k-1)) \\
&= \frac{\partial^2 f_l(x)}{\partial x^2} \bigg|_{\hat{\underline{x}}(k-1/k-1)} \times \text{Tr} \left[(\underline{x}(k-1) - \hat{\underline{x}}(k-1/k-1)) (\underline{x}(k-1) - \hat{\underline{x}}(k-1/k-1))^T \right] \quad (1.224) \\
&= \text{Tr} \left[(\underline{x}(k-1) - \hat{\underline{x}}(k-1/k-1)) (\underline{x}(k-1) - \hat{\underline{x}}(k-1/k-1))^T \right] \times \frac{\partial^2 f_l(x)}{\partial x^2} \bigg|_{\hat{\underline{x}}(k-1/k-1)}
\end{aligned}$$

Etant donné l'expression, la valeur moyenne de $\Phi_l(k)$ étant donné les $k-1$ dernières observations disponibles peut être approximée par :

$$E[\Phi_l(k) / y(0), \dots, y(k-1)] \approx \text{Tr}[P(k-1/k-1)] \times \frac{\partial^2 f_l(x)}{\partial x^2} \bigg|_{\hat{\underline{x}}(k-1/k-1)} \quad (1.225)$$

Cette approximation présente l'avantage d'être facilement exploitable dès lors que l'on dispose de la matrice de covariance de l'erreur. Il vient alors :

$$\begin{aligned}
\bar{\Phi}(k) &= E[\Phi(k) / y(0), \dots, y(k-1)] \\
&\approx \sum_{l=1}^L \left[\underbrace{0 \cdots 0}_{l-1} \quad 1 \quad \underbrace{0 \cdots 0}_{L-l} \right]^T \text{Tr}[P(k-1/k-1)] \times \frac{\partial^2 f_l(x)}{\partial x^2} \bigg|_{\hat{\underline{x}}(k-1/k-1)} \quad (1.226)
\end{aligned}$$

A ce stade du développement, exprimons l'expression de l'estimation *a priori* du vecteur d'état à l'instant k et l'erreur *a priori* commise associée :

$$\hat{\underline{x}}(k/k-1) = E[\underline{x}(k) / y(0), \dots, y(k-1)] \approx f(\hat{\underline{x}}(k-1/k-1)) + \frac{1}{2} \bar{\Phi}(k) \quad (1.227)$$

et

$$\begin{aligned}
\tilde{\underline{x}}(k/k-1) &= \underline{x}(k) - \hat{\underline{x}}(k/k-1) \\
&\approx f(\hat{\underline{x}}(k-1/k-1)) + \nabla_f(\underline{x}) \Big|_{\underline{x}=\hat{\underline{x}}(k-1/k-1)} (\underline{x}(k-1) - \hat{\underline{x}}(k-1/k-1)) + \frac{1}{2} \Phi(k) \\
&\quad + G(k)\underline{u}(k) - f(\hat{\underline{x}}(k-1/k-1)) - \frac{1}{2} \overline{\Phi}(k)
\end{aligned} \tag{1.228}$$

En supposant que $\overline{\Phi}(k) \approx \Phi(k)$, l'erreur *a priori* devient :

$$\tilde{\underline{x}}(k/k-1) \approx \nabla_f(\underline{x}) \Big|_{\underline{x}=\hat{\underline{x}}(k-1/k-1)} (\underline{x}(k-1) - \hat{\underline{x}}(k-1/k-1)) + G(k)\underline{u}(k) \tag{1.229}$$

Dès lors, la matrice de covariance de l'erreur *a priori* satisfait :

$$P(k/k-1) = \nabla_f(\underline{x}) \Big|_{\underline{x}=\hat{\underline{x}}(k-1/k-1)} P(k-1/k-1) \nabla_f^T(\underline{x}) \Big|_{\underline{x}=\hat{\underline{x}}(k-1/k-1)} + G(k)Q(k)G^T(k) \tag{1.230}$$

C'est la même équation de mise à jour de la matrice de covariance de l'erreur que pour l'EKF. Puis, effectuons le développement de Taylor du 2^{ème} ordre de la fonction d'observation g , autour de la dernière estimation du vecteur d'état à savoir $\hat{\underline{x}}(k/k-1)$. Comme précédemment, on obtient :

$$g(\hat{\underline{x}}(k)) \approx g(\hat{\underline{x}}(k/k-1)) + \nabla_g(\underline{x}) \Big|_{\underline{x}=\hat{\underline{x}}(k/k-1)} (\underline{x}(k) - \hat{\underline{x}}(k/k-1)) + \frac{1}{2} \Psi(k) \tag{1.231}$$

avec

$$\begin{aligned}
\Psi(k) &= \sum_{l=1}^L \left[\underbrace{0 \quad \dots \quad 0}_{l-1} \quad 1 \quad \underbrace{0 \quad \dots \quad 0}_{L-l} \right]^T \\
&\quad \times (\underline{x}(k) - \hat{\underline{x}}(k/k-1))^T \frac{\partial^2 g_l(\underline{x})}{\partial \underline{x}^2} \Big|_{\hat{\underline{x}}(k/k-1)} (\underline{x}(k) - \hat{\underline{x}}(k/k-1)) \\
&= \sum_{l=1}^L \left[\underbrace{0 \quad \dots \quad 0}_{l-1} \quad 1 \quad \underbrace{0 \quad \dots \quad 0}_{L-l} \right]^T \Psi_l(k)
\end{aligned} \tag{1.232}$$

où $\frac{\partial^2 g_l(\underline{x})}{\partial \underline{x}^2} \Big|_{\hat{\underline{x}}(k/k-1)}$ dénote la dérivée seconde de la fonction non-linéaire g par rapport à la $l^{\text{ème}}$

composante du vecteur d'état et évaluée en $\hat{\underline{x}}(k/k-1)$.

De même que précédemment, on peut noter que :

$$\begin{aligned}
\Psi_l(k) &= (\underline{x}(k) - \hat{\underline{x}}(k/k-1))^T \frac{\partial^2 g_l(\underline{x})}{\partial \underline{x}^2} \Big|_{\hat{\underline{x}}(k/k-1)} (\underline{x}(k) - \hat{\underline{x}}(k/k-1)) \\
&= \text{Tr} \left[(\underline{x}(k) - \hat{\underline{x}}(k/k-1)) (\underline{x}(k) - \hat{\underline{x}}(k/k-1))^T \right] \times \frac{\partial^2 g_l(\underline{x})}{\partial \underline{x}^2} \Big|_{\hat{\underline{x}}(k/k-1)}
\end{aligned} \tag{1.233}$$

ainsi que :

$$\begin{aligned}\bar{\Psi}(k) &= E[\Psi(k) / y(0), \dots, y(k-1)] \\ &\approx \sum_{l=1}^L \left[\underbrace{0 \quad \dots \quad 0}_{l-1} \quad 1 \quad \underbrace{0 \quad \dots \quad 0}_{L-l} \right]^T \text{Tr}[P(k-1/k-1)] \times \left. \frac{\partial^2 g_l(x)}{\partial x^2} \right|_{\hat{x}(k/k-1)}\end{aligned}\quad (1.234)$$

En faisant l'approximation $\bar{\Psi}(k) \approx \Psi(k)$, on peut alors exprimer l'innovation comme suit :

$$\begin{aligned}y(k) - g(\hat{x}(k/k-1)) \\ &\approx g(\hat{x}(k/k-1)) + \nabla_g(x) \Big|_{x=\hat{x}(k/k-1)} (\underline{x}(k) - \hat{x}(k/k-1)) + \frac{1}{2} \Psi(k) + v(k) - g(\hat{x}(k/k)) \\ &\approx \nabla_g(x) \Big|_{x=\hat{x}(k/k-1)} (\underline{x}(k) - \hat{x}(k/k-1)) + \frac{1}{2} \Psi(k) + v(k) \\ &\approx \nabla_g(x) \Big|_{x=\hat{x}(k/k-1)} (\underline{x}(k) - \hat{x}(k/k-1)) + \frac{1}{2} \bar{\Psi}(k) + v(k)\end{aligned}\quad (1.235)$$

L'innovation dépend dans ce cas de $\bar{\Psi}(k) \approx \Psi(k)$. Dès lors la mise à jour du vecteur d'état vérifie :

$$\hat{x}(k/k) = \hat{x}(k/k-1) + K(k) \left[y(k) - f(\hat{x}(k/k-1)) - \frac{1}{2} \bar{\Psi}(k) \right] \quad (1.236)$$

Equation du modèle	$\underline{x}(k) = f(\underline{x}(k-1)) + G(k)\underline{u}(k)$
Equation d'observation	$y(k) = g(\underline{x}(k)) + v(k)$
Information <i>a priori</i>	$E[\underline{u}(k)] = 0$ et $E[v(k)] = 0$ $E[\underline{u}(k)v(l)] = 0 \quad \forall k, l$ $E[\underline{u}(k)\underline{u}^T(l)] = Q(k)\delta(k-l)$ $E[v(k)v(l)] = R(k)\delta(k-l)$ $E[\underline{x}_0(k)\underline{u}^T(k)] = 0 \quad \forall k \geq 0$ $E[\underline{x}_0(k)v(k)] = 0 \quad \forall k \geq 0$
Equations du filtre	$\hat{x}(k/k-1) \approx f(\hat{x}(k-1/k-1)) + \frac{1}{2} \bar{\Phi}(k)$ $\hat{x}(k/k) = \hat{x}(k/k-1) + K(k) \left[y(k) - f(\hat{x}(k/k-1)) - \frac{1}{2} \bar{\Psi}(k) \right]$ avec $\bar{\Phi}(k) \approx \sum_{l=1}^L \left[\underbrace{0 \quad \dots \quad 0}_{l-1} \quad 1 \quad \underbrace{0 \quad \dots \quad 0}_{L-l} \right]^T \text{Tr}[P(k-1/k-1)] \times \left. \frac{\partial^2 f_l(x)}{\partial x^2} \right _{\hat{x}(k-1/k-1)}$ et $\bar{\Psi}(k) \approx \sum_{l=1}^L \left[\underbrace{0 \quad \dots \quad 0}_{l-1} \quad 1 \quad \underbrace{0 \quad \dots \quad 0}_{L-l} \right]^T \text{Tr}[P(k-1/k-1)] \times \left. \frac{\partial^2 g_l(x)}{\partial x^2} \right _{\hat{x}(k/k-1)}$

Expressions du gain	$K(k) = P(k/k-1) \nabla_g^T(x) \Big _{x=\hat{x}(k/k-1)}$ $\left[\nabla_g(x) \Big _{x=\hat{x}(k/k-1)} P(k/k-1) \nabla_g^T(x) \Big _{x=\hat{x}(k/k-1)} + R(k) \right]^{-1}$
Variance <i>a posteriori</i>	$P(k/k) = \left[I - K(k) \nabla_g(x) \Big _{x=\hat{x}(k/k-1)} \right] P(k/k-1)$
Variance <i>a priori</i>	$P(k/k-1) = \nabla_f(x) \Big _{x=\hat{x}(k-1/k-1)} P(k-1/k-1) \nabla_f^T(x) \Big _{x=\hat{x}(k-1/k-1)}$ $+ G(k)Q(k)G^T(k)$
Conditions initiales	$\hat{x}(0/0) = E[x(0)]$ $P(0/0) = P(0) = E\{[x(0) - \hat{x}(0/0)][x(0) - \hat{x}(0/0)]^T\}$

1.7 Mise en œuvre du filtre de Kalman par sigma point

Dans le cas d'un filtre de Kalman par sigma point, la distribution du vecteur d'état est supposée Gaussienne. Elle est caractérisée par un ensemble de points, appelés sigma-points, qui se situent le long des axes principaux de la matrice de covariance de la variable aléatoire. Si le vecteur d'état est de taille L , il y a $2L+1$ sigma points : deux paires placées le long de chaque axe principal de la distribution et la moyenne.

Ces sigma-points se propagent au travers d'un système non-linéaire. Une combinaison des sigma points *a posteriori* permet alors d'obtenir une estimation de la valeur moyenne et de la matrice de corrélation de la variable aléatoire qui a subi la transformation non-linéaire.

D'une part, le filtre de Kalman sans parfum (UKF) est fondé sur la transformée sans parfum. D'autre part, le filtre de Kalman par différence centrale (CDKF) est fondé sur la formule d'interpolation de Sterling. Dans la suite, nous présentons l'UKF.

1.7.1 Transformée sans parfum et UKF

La transformation sans parfum, unscented transform (UT) en anglais, vise à estimer les statistiques d'ordre 2 d'une variable aléatoire $\mathbf{x}$ de dimension L qui subit une transformation non-linéaire arbitraire suivante :

$$\mathbf{y} = \mathbf{g}(\mathbf{x}) \quad (1.237)$$

On connaît *a priori* la moyenne et la matrice de covariance que l'on note respectivement $\bar{\mathbf{x}}$ et $\mathbf{P}_x$. L'objet de la transformée sans parfum est d'estimer les moments d'ordre 2 de la variable aléatoire $\mathbf{y}$. Pour cela, on considère $2L+1$ sigma-points que l'on pondère à l'aide des poids pour obtenir l'ensemble $\mathbf{S}_i = \{w_i, \chi_i\}$. Le principe de la transformée sans parfum est de s'approcher « au mieux »⁵ de la valeur moyenne $\bar{\mathbf{y}}$ de variable aléatoire $\mathbf{y}$ à l'aide des sigma-points et des poids associés. Cet ensemble est choisi de façon déterministe comme suit :

$$\chi_0 = \bar{\mathbf{x}} \text{ et } w_0 = \frac{\kappa}{L + \kappa} \quad (1.238)$$

⁵ C'est-à-dire en faisant que la valeur estimée de la moyenne de $\mathbf{y}$ se rapproche du développement de Taylor de $\bar{\mathbf{y}}$ autour de $\bar{\mathbf{x}}$ jusqu'à un certain ordre.

$$\chi_i = \bar{\mathbf{x}} + \left(\sqrt{(L + \kappa) \mathbf{P}_x} \right)_i, \quad w_i = \frac{1}{2(L + \kappa)}, \quad \text{pour } i = 1, \dots, L \quad (1.239)$$

$$\chi_i = \bar{\mathbf{x}} - \left(\sqrt{(L + \kappa) \mathbf{P}_x} \right)_i, \quad w_i = \frac{1}{2(L + \kappa)}, \quad \text{pour } i = L + 1, \dots, 2L \quad (1.240)$$

où κ est un paramètre de mise à l'échelle et $\left(\sqrt{(L + \kappa) \mathbf{P}_x} \right)_i$ denote la $i^{\text{ème}}$ colonne du facteur de Cholesky de la matrice de covariance de la variable aléatoire $\mathbf{x}$ pondérée, à savoir $(L + \kappa) \mathbf{P}_x$. On propage alors chaque sigma-point à travers la fonction non-linéaire pour obtenir les sigma-points *a posteriori* :

$$\Psi_i = \mathbf{g}(\chi_i), \quad \text{pour } i = 0, \dots, 2L \quad (1.241)$$

On en déduit alors la moyenne, la matrice de covariance et la matrice d'intercovariance entre $\mathbf{x}$ et $\mathbf{y}$ comme suit :

$$\bar{\mathbf{y}} \approx \sum_{i=0}^{2L} w_i \Psi_i \quad (1.242)$$

$$\mathbf{P}_y \approx \sum_{i=0}^{2L} w_i (\Psi_i - \bar{\mathbf{y}})(\Psi_i - \bar{\mathbf{y}})^T \quad (1.243)$$

$$\mathbf{P}_{xy} \approx \sum_{i=0}^{2L} w_i (\chi_i - \bar{\mathbf{x}})(\Psi_i - \bar{\mathbf{y}})^T \quad (1.244)$$

Les sigma-points peuvent être mis à l'échelle en introduisant un facteur κ . Ainsi, la distance entre $i^{\text{ème}}$ sigma-point de la valeur moyenne $\bar{\mathbf{x}}$, à savoir $|\chi_i - \bar{\mathbf{x}}|$, est proportionnelle à $\sqrt{(L + \kappa)}$. Quand $\kappa = 0$, la distance $|\chi_i - \bar{\mathbf{x}}|$ est proportionnelle à $\sqrt{L}$. Quand $\kappa > 0$, les sigma-points seront plus éloignés de $\bar{\mathbf{x}}$ et quand $\kappa < 0$, les sigma points se rapprochent de $\bar{\mathbf{x}}$. Cependant, le choix du facteur d'échelle et des poids doit garantir les propriétés de la matrice de corrélation de la variable $\mathbf{y}$. Les études menées ont abouti à la définition des sigma-points suivants :

$$\chi_0 = \bar{\mathbf{x}}, \quad w_0^{(m)} = \frac{\lambda}{L + \lambda}, \quad (1.245)$$

$$\chi_i = \bar{\mathbf{x}} + \left(\sqrt{(L + \lambda) \mathbf{P}_x} \right)_i, \quad i = 1, \dots, L, \quad w_0^{(c)} = \frac{\lambda}{L + \lambda} + (1 - \alpha^2 + \beta), \quad i = 0 \quad (1.246)$$

$$\chi_i = \bar{\mathbf{x}} - \left(\sqrt{(L + \lambda) \mathbf{P}_x} \right)_i, \quad i = L + 1, \dots, 2L, \quad w_i^{(m)} = w_i^{(c)} = \frac{1}{2(L + \lambda)}, \quad i = 1, \dots, 2L \quad (1.247)$$

avec

$$\lambda = \alpha^2(L + \kappa) - L \quad (1.248)$$

On en déduit alors la moyenne, la matrice de covariance et la matrice d'intercovariance entre $\mathbf{x}$ et $\mathbf{y}$ comme suit :

$$\bar{\mathbf{y}} \approx \sum_{i=0}^{2L} w_i^{(m)} \Psi_i \quad (1.249)$$

$$\mathbf{P}_y \approx \sum_{i=0}^{2L} w_i^{(c)} (\boldsymbol{\psi}_i - \bar{\mathbf{y}})(\boldsymbol{\psi}_i - \bar{\mathbf{y}})^T \quad (1.250)$$

$$\mathbf{P}_{xy} \approx \sum_{i=0}^{2L} w_i^{(c)} (\boldsymbol{\chi}_i - \bar{\mathbf{x}})(\boldsymbol{\psi}_i - \bar{\mathbf{y}})^T \quad (1.251)$$

1.7.2 Transformée sans parfum et UKF

Dans le cas de l'estimation d'un vecteur d'état de taille L , ce vecteur d'état peut subir deux transformations non-linéaires. La première lors de la mise du vecteur d'état et la seconde lorsque l'on relie le vecteur d'état aux observations. En outre, on rappelle que le filtre de Kalman s'exprime en fonction de la matrice de corrélation de l'innovation et de la matrice d'intercorrélation entre l'état prédit et l'innovation. Le filtre de Kalman sans parfum se fonde sur la transformée sans parfum pour tenir compte des non-linéarités de la représentation de l'espace d'état du système.